

雑談を通して高齢者の健康状態を把握する アンケート対話システムの構築

銭本友樹^a・吉田麻里子^a・堀涼^a・
浦田真由^a・井上愛子^b・林尊弘^c・東中竜一郎^a

加齢により心身が衰えた状態である「フレイル」の早期発見は、高齢者の健康寿命の延伸において重要である。従来、フレイルの発見には身体的、心理的、および社会的な状態について尋ねる質問を含むアンケートが用いられてきた。フレイルの早期発見のためには、そのようなアンケートへの回答を定期的に行う必要があるが、回答項目数が多いために、定期的なアンケートへの回答は高齢者にとって大きな負担である。この課題を解決するため、本研究では、日常的な雑談の中でアンケートの回答を収集するアンケート対話システムを提案する。アンケート対話システムは、複数ターンにわたって対話を誘導し、自然な対話の流れでアンケートに含まれる質問を尋ねることで、アンケートの回答を収集する。そして、対話の中で聞き出した応答を、アンケートにおけるその質問の回答形式に対応づけることで、アンケートと同じ回答形式での回答を収集する。アンケート対話システムを用いることで、対話システムとの単なる雑談がアンケートへの回答となるため、高齢者の負担を軽減しつつフレイルの定期的な診断が可能となると考えられる。本研究では、アンケート対話システムが自然に質問を行うことができること、およびアンケート対話システムによって得られた回答が、紙面アンケートの回答と比較的高い一致率を持つことを、クラウドソーシングを用いた評価実験と、高齢者を対象とした実証実験を通して確認した。

キーワード：対話システム、フレイル、質問誘導、大規模言語モデル

Construction of a Questionnaire Dialogue System for Assessing the Health Status of Older Adults through Casual Conversation

YUKI ZENIMOTO^a, MARIKO YOSHIDA^a, RYO HORI^a, MAYU URATA^a, AIKO INOUE^b,
TAKAHIRO HAYASHI^c and RYUICHIRO HIGASHINAKA^a

In an aging society, extending the healthy life expectancy of older adults is a critical

^a 名古屋大学大学院情報学研究科, Graduate School of Informatics, Nagoya University

^b 名古屋大学未来社会推進機構, Institutes of Innovation for Future Society, Nagoya University

^c 愛知医療学院大学リハビリテーション学部, Aichi Medical College of Rehabilitation

本論文の一部は、言語処理学会第31回年次大会およびThe 29th Workshop on the Semantics and Pragmatics of Dialogue (SemDial2025)で発表済みのものである。

issue. In particular, early detection of frailty, a condition between healthy aging and the need for long-term care, is especially important for preventive care. Although paper-based questionnaires are commonly used for this purpose, their length and the need for repeated administration place a considerable burden on older individuals, reducing response rates and accuracy. To address this issue, we propose a questionnaire dialogue system that elicits responses to questionnaire items through casual conversation. This system generates utterances that naturally guide the conversation toward target questions using Chain-of-Thought prompting with a large language model. In addition, it maps free-form user responses to predefined questionnaire choices, allowing responses to be collected in the same format as conventional paper-based questionnaires. We conducted human evaluation experiments, followed by a two-week demonstration experiment in which older adults interacted with our system. The results show that our proposed approach achieves relatively high agreement with paper-based questionnaires.

Key Words: *spoken dialogue system, health application, question-guiding, large language model*

1 はじめに

少子高齢化が進む現代社会において、高齢者の健康寿命を延ばすことは、医療および福祉の持続可能性を確保する上で重要な課題である。この課題への対策として、健康な状態と要介護状態の中間に位置し、身体機能や認知機能の低下がみられる状態であるフレイル (Fried et al. 2001; Dent et al. 2019) の早期発見が期待されている。フレイルは、適切な介入により健康な状態へと回復する可能性があるとしており、健康寿命の延伸に向けて、フレイルをいかに早期発見するかが重要となっている。

フレイルを発見する方法としては、身体的、心理的、社会的な状態などの様々な状態を測定するアンケート(以下、フレイルアンケートと呼ぶ)が複数提案されてきた(村瀬 他 2002; Wilson et al. 2005; 舩田 他 2012; 佐竹 2018; Hayashi et al. 2026)。フレイルの早期発見のためには、これらのフレイルアンケートを用いた調査を定期的実施する必要がある。しかし、すべてのフレイルアンケートに回答する場合、回答項目数は100以上にも及ぶため、定期的なフレイルアンケートへの回答は高齢者にとって大きな負担である。

アンケートに回答する負担を軽減する手法として、対話システムを用いたアプローチが考えられている(Johnston et al. 2013; Xiao et al. 2020)。このアプローチでは、ユーザは1人でアンケートに回答するのではなく、対話システムからの質問に答えるというインタビュー形式でアンケートへの回答を行う。これにより、ユーザは紙面上で多数の質問に1つずつ回答する代わりに、対話の流れの中で自然に応答するだけでよくなるため、回答の負担が軽減されと考えられる。しかし、対話の中で何度も立て続けに質問をされるのは高齢者にとってなお一定の負




図 1: アンケート対話システムがアンケートの回答を収集する処理の全体像

担を伴う行為であり、定期的に何度も実施することは依然として困難である。

このような背景から、本研究では、日常的な雑談の中でアンケートの回答を自然に収集するアンケート対話システムを提案する。アンケート対話システムを用いることで、対話システムとの雑談がアンケートへの回答となるため、高齢者の負担を軽減しつつフレイルの定期的な診断が可能となると考えられる。図 1 に、アンケート対話システムがアンケートの回答を収集する処理の全体像を示す。図 1 にあるように、アンケート対話システムは、主に 2 つの要素によって構成される。1 つ目は、複数ターンにわたって対話を誘導し、雑談の文脈を損なわず自然な流れで目標の質問（以下、目標質問と呼ぶ）を尋ねる質問誘導である。この質問誘導では、大規模言語モデル (Large Language Model ; LLM) (Brown et al. 2020) に思考過程を段階的に出力させる Chain-of-Thought (CoT) プロンプト (Wei et al. 2022; Kojima et al. 2022) を与えることで、自然な誘導を行う発話と、実際に目標質問を尋ねる発話を生成する。2 つ目は、応答と選択肢の対応づけである。この対応づけでは、LLM を用いて、目標質問に対する自由応答を、その目標質問に定められた選択肢のいずれかに対応づける。この対応づけにより、自由応答を紙面アンケートと同じ回答形式に変換し、アンケート結果を得る。

本研究では、アンケート対話システムを評価するため、クラウドソーシングを用いたテキスト対話による評価実験および高齢者を対象とした音声対話による実証実験を行った。クラウド

ソーシング実験では、まず一般的な質問を対象として質問誘導を行った対話（以下、質問誘導対話と呼ぶ）を実施し、質問誘導能力を対話者自身による評価と第三者評価で評価した。その結果、CoT プロンプトを用いたシステムは、所望の質問を自然に尋ねることができることが示された。続いて、フレイルアンケートを対象とした質問誘導対話を実施し、対話システムを用いて得られた回答と、紙面アンケートによる回答の一致率を評価した。その結果、アンケート対話システムによって得られた回答は、従来の紙面アンケートと比較的高い一致率を持つことが示された。実証実験では、フレイルアンケートを対象とした質問誘導対話を高齢者の自宅で2週間実施し、対話システムを用いて得られた回答と、紙面アンケートによる回答の一致率を評価した。その結果、アンケート対話システムによって得られた回答は、紙面アンケートと比較的高い一致率を持つことが示され、アンケート対話システムの実環境における有効性が確認された。

本研究の貢献は以下の通りである。

- CoT プロンプトを用いた質問誘導と、LLM を用いた応答と選択肢の対応づけを用いて、従来の紙面アンケートによる回答と比較的高い一致率の回答を雑談の中で収集するアンケート対話システムを実現した。
- テキスト対話によるクラウドソーシングでの評価実験を通して、CoT プロンプトを用いた質問誘導が、所望の質問を自然に尋ねることができることを示した。
- 音声対話による実環境での実証実験を通して、アンケート対話システムの実環境における有効性を示すとともに、実環境では、質問に対して必ずしも明確な回答が得られるわけではなく、曖昧な応答や質問とは無関係な応答への対処が必要であることを明らかにした。

本論文の構成は以下の通りである。2 節では、ユーザからアンケート回答を収集する対話システムと、所望の質問を自然に行うための質問誘導に関する関連研究について述べる。3 節では、雑談の中で質問を自然に尋ねる質問誘導と、応答と選択肢の対応づけを含むアンケート対話システムの詳細について述べる。4 節では、クラウドソーシングを介したテキスト対話による評価実験について述べる。5 節では、高齢者を対象とした音声対話による実証実験について述べる。最後に、6 節では、本研究のまとめと今後の課題について述べる。

2 関連研究

ここでは関連研究として、対話システムを用いてユーザからアンケートの回答を収集する研究と、特定の発話を自然に行うための対話誘導研究について述べる。

2.1 対話システムを用いてユーザからアンケートの回答を収集する研究

対話システムを用いてユーザからアンケートの回答を収集する研究は、すべての質問項目があらかじめ決まっている構造化インタビューを対象とした研究と、事前に定義された一部の質問を中心として、動的に質問を生成し柔軟にユーザの意見を深掘りする半構造化インタビューを対象とした研究に大別できる。

構造化インタビューに取り組んだ研究として、Johnston et al. (2013) らは、アンケート調査を行う音声対話システムを提案した。このシステムは、あらかじめ定義された質問に基づいて対話を進行し、ユーザの音声応答を認識しながら、調査項目に対応する回答を収集する。加えて、曖昧な応答に対する確認や、不十分な回答に対する追質問といった対話戦略を導入することで、回答の正確性と一貫性の向上を図っている。人間評価実験の結果、提案システムは人間のインタビューと比較しても大きく劣らない回答品質を達成しつつ、調査の標準化やバイアス低減の観点で有効であることが示された。また、Kobori et al. (2016) は、構造化インタビューを行う対話システムにおいて、各質問への回答後に雑談を適度に挿入することで、質問のみを繰り返すシステムと比較して、ユーザからの印象を向上できることを示した。さらに、Nagasawa et al. (2024) らは、音声特徴や身体動作などの非言語情報をマルチモーダルセンサで取得し、ユーザの発話意欲をリアルタイムに推定することで、対話システムが動的に質問を選択する手法を提案した。そして、実験の結果、発話意欲が高いと推定された場合は現在のトピックを継続し、低い場合はトピックを切り替える戦略を導入することで、固定の順番で質問を尋ねる戦略と比較してより自然な情報収集が実現できることを確認した。

半構造化インタビューに取り組んだ研究として、Xiao et al. (2020) らは、自由記述形式のアンケートの回答を収集する対話システムを提案した。このシステムは、ユーザの回答内容を解釈した上で動的に深掘り質問を生成し、より深い情報を収集する。約 600 人を対象とした人間評価実験の結果、従来のアンケート調査と比較して、本対話システムによって収集された回答は情報量や関連性、および総合的な回答品質において有意に優れていることが示された。Geiecke and Jaravel (2024) は、社会調査における質的インタビューの自動化を目的として、指定したトピックについて対話相手の意見を深掘ることができるインタビューシステムを提案した。このシステムは、社会学における質的面接の原則 (Small and Calarco 2022) を反映したプロンプトを用いることで、専門家による質的インタビューを模倣している。そして、人間評価実験を通して、システムが人間のインタビューに匹敵する品質でのインタビューが可能であることが示された。また、Hashimoto et al. (2025) は、看護師のキャリア面談の効率化を目的として、事前に看護師からキャリアに関する情報を収集するスロットフィリング型の対話システムを提案した。従来のスロットフィリング型対話システムでは、事前に定義されたスロット集合に基づいて情報を収集するため、情報収集の柔軟性に限界があった。本研究では、この課題に対応するため、LLM を用いて対話の流れに応じて新しいスロットを動的に生成する枠組みを導入した。

そして、シミュレーション実験および人間評価実験を通して、提案手法が固定のスロットに基づく手法や単純な動的スロット生成手法よりも情報収集量と対話自然性の両面で優れていることが示された。

これら対話システムを用いてユーザからアンケートの回答を収集する先行研究は、アンケートをそのまま対話に適用している。一方で本研究では、日常的な雑談を対象とし、対話の文脈に関係なく、所望の質問を自然に行うことを目標としている。

2.2 特定の発話を自然に行うための対話誘導研究

本研究で扱う質問誘導のように、対話の中で特定の発話を自然に行うための対話誘導も活発に研究されている。目標となる発話の性質に着目すると、先行研究は、所望の単語を含む発話の生成、所望の発話と同じ発話の生成、所望の質問と同じ質問の生成の3つに分類できる。

所望の単語を含む発話の生成に取り組んだ研究として、Tang et al. (2019) らは、任意の文脈から、所望の単語を含む発話を自然に行うことができる対話誘導手法を提案した。具体的には、システム発話に含めるキーワードを徐々に目標の単語に近づくよう制御する談話レベルの対話制御モジュールと、指定したキーワードに基づき発話を生成するターンレベルの発話生成モジュールを組み合わせることで、目標単語への自然な誘導を行う発話の生成を実現した。人間評価実験の結果、提案手法を用いた対話システムが、単純な雑談システムやルールベースの誘導と比べて、目標単語への到達率と対話の滑らかさの両面で優れていることが示された。この Tang et al. (2019) らのアプローチに基づき、現在の対話文脈から目標単語へ至るまでの中間的な話題やキーワードを、対話グラフや知識グラフなどの外部知識を用いて選定する手法 (Qin et al. 2020; Xu et al. 2020; Zhong et al. 2021) や、複数ターン先を見据えた長期的な対話戦略を導入する手法 (Yang et al. 2022; Kishinami et al. 2022) が提案されており、誘導性能の向上が図られている。

所望の発話と同じ発話の生成に取り組んだ研究として、Gupta et al. (2022) は、現在の文脈と目標の発話の間を自然に繋ぐ文を生成する手法を提案した。この手法では、一発話内で特定の話題への遷移を行っている対話が収集された Otter データセット (Sevegnani et al. 2021) と、知識グラフである ConceptNet (Speer et al. 2017) を用いて GPT-2 ベースの言語モデル (Radford et al. 2019) を訓練することで、現在の対話文脈と目標文を自然に繋げる発話を生成している。人間評価実験の結果、提案手法は元の GPT-2 や ConceptNet を用いた GPT-2 ベースの応答生成モデル (Ji et al. 2020) と比較して、誘導の滑らかさや発話の情報量で優れていることが示された。

所望の質問と同じ質問の生成に取り組んだ研究としては、Horiuchi and Higashinaka (2021, 2023) の質問誘導対話システムが挙げられる。Horiuchi and Higashinaka (2023) は、質問を尋ねる数発話前から対話を誘導し、自然に質問を尋ねることができる対話システムを提案した。こ




図 2: 質問誘導対話の例

の対話システムは、人間同士の質問誘導対話データを用いて、日本語対話用の Transformer モデル (Sugiyama et al. 2023) をファインチューニングすることで構築されている。人間との対話実験を通して、本システムは一般的に尋ねることが難しいとされる質問であっても、自然な誘導が実施できることが示された。本研究では、この質問誘導の枠組みを基盤として、LLM および CoT プロンプトを活用することで、所望の質問への誘導の自然さをさらに高めることを目指す。また、質問誘導を、一般的な質問ではなくフレイルアンケートへ適用し、質問誘導を通して得られた回答の信頼性や、実環境での質問誘導能力の検証を行う。

3 提案手法

本研究では、雑談の中でアンケートへの回答を聞き出すアンケート対話システムを提案する。アンケート対話システムは、対話を誘導し雑談の中で自然に質問を尋ねる質問誘導と、応答と選択肢の対応づけによって構成される。

3.1 Chain-of-Thought を用いた質問誘導

本研究で目指す質問誘導の詳細と、LLM を用いて自然な質問誘導を実現するためのプロンプト設計について説明する。図 2 に、我々が目指す質問誘導の具体例を示す。この図では、「最近料理にはまっているんですね」や「忙しいとご飯食べる時間もないですね」といった発話により、「普段の食事は何回取られますか?」という目標質問を自然に尋ねるための文脈が形

文脈を考慮して、対話を誘導しながら自然な話の流れで目標質問を尋ねるセリフを出力してください。
 対話を誘導するためのthoughtとして、「目標質問を尋ねる話の流れになっているか」、「現在は何についての話か」「目標質問は何についての質問か」「どうすれば自然に目標質問を尋ねることができるか」を考えた後に、セリフを出力してください。
 セリフには目標質問と全く同じ文章を含めてください。
 長い出力は禁止です、出力は簡潔に短くしてください。
 以下のような接続詞を使って無理やり話の流れを大きく変えることは絶対に禁止です。文脈に合った誘導をしてください。
 # 禁止接続詞
 「ところで」、「そういえば」、「ちなみに」、「それはさておき」、「それにしても」、「さて」、「話は変わ」、「例えば」（後略）

<ショット例>
 # 目標質問
 あなたはバーで飲みすぎて失敗したことはありますか？
 # 文脈
 ユーザ：こんばんは。すっかり夜ですね。
 システム：こんばんは、そうですね。あなたはスマホ以外にカメラを持っていますか？
 ユーザ：はい、一眼レフとデジカメを1台ずつ持っていますよ。
 システム：すごいですね。最近はカメラを持っている人も見かけなくなった気がします。なにか撮るためのものなのですか？
 ユーザ：最近はスマホのカメラの性能がいいですもんね。最近は主に子供のイベント時に使用していますね。
 システム：おお、それはいい使い方ですね。絶対に撮り逃しできませんものね。
 ユーザ：はい。一眼レフだとスマホの容量も気にせず撮れるし、やっぱり綺麗に仕上がるんですよ。
 システム：確かに、容量気になりますね。撮った写真は、現像してアルバムですか？
 ユーザ：そうです。いそいそとアルバムを作っています。たまに子供と一緒に見返すのが楽しいんですよ。
 システム：子供が大人になったときにも見返せますもんね。そういえば話が変わるのですが、最近スマホをなくして大変だったことがありますか？
 ユーザ：それは一大事です！スマホは無事見つかりましたか？
 # thought
 Let's think step by step.
 目標質問を尋ねる話の流れになっているか：いいえ
 現在は何についての話か：カメラやスマホをなくしたこと
 目標質問は何についての質問か：バーで飲みすぎた失敗
 どうすれば自然に目標質問を尋ねることができるか：スマホをなくした理由をバーで飲みすぎたことにすることで、自然に目標質問を尋ねることができそうである。そこで、文脈に沿った応答をした後、バーで飲みすぎてスマホをなくしたことを話し、同じような経験を持っているかどうかを尋ねるという目的で目標質問を尋ねる。
 # 出力
 システム：バーで飲みすぎて忘れていたみたいです。今の時代、スマホがないと生きていけないと感じました。あなたはバーで飲みすぎて失敗したことはありますか？
 <ショット例>

目標質問
 {target_question}
 # 文脈
 {context}
 # thought
 Let's think step by step.

図 3: 質問誘導プロンプト C の具体例. {target_question} には実際に尋ねる目標質問が入り, {context} には対話履歴が入る.

成されており、最終的に自然な流れで質問を尋ねることができている。このように、目標質問を自然な流れで尋ねるには、質問を尋ねる前の発話から徐々に対話を誘導し、質問を自然に尋ねることができる文脈を形成することが望ましい (Yang et al. 2022; Horiuchi and Higashinaka 2023). また、このような質問誘導を実現するためには、現在の対話文脈を適切に理解し、その文脈と目標質問との関連性を踏まえて発話を生成する必要がある。そのため、LLM に対してプロンプトで単に誘導を行うよう指示するだけでは、自然な誘導は実現できないと考えられる。以上を踏まえ、本研究では、段階的な誘導を行うことと、CoT を用いて質問誘導に必要な推論過程を明示的に出力させることの 2 つを方針として、質問誘導を行うプロンプトを設計する。


```
質問とそれに対する被験者の回答から、被験者の回答が選択肢のどれに対応するかを出力してください。
被験者の回答には誤字や省略があり、曖昧な回答である可能性があります。それらを考慮し、可能な限り意味の近い選択肢への対応づけを行ってください。
選択肢のみを出力してください。
選択肢のどれにも該当しない場合は、「無効な回答」と出力してください。
# 質問
{target_question} (選択肢: {options})
# 被験者の回答
{answer}
# 回答と選択肢の対応づけ
```

図 4: 応答と選択肢の対応づけプロンプト. {target_question} には実際に尋ねる目標質問, {options} にはその目標質問の選択肢, {answer} にはその目標質問に対するユーザの応答が入る.

1 つ目の方針に基づき, 本研究では, 目標質問への誘導となる発話を 2 回行い, その後の 3 回目の発話で目標質問を尋ねる構成を採用する. そして, この段階的な誘導を実現するために, 各段階に対応した個別のプロンプトを用いる. 具体的には, 次に示す 3 種類のプロンプトを作成し, これらを順に用いて LLM で誘導発話および質問発話を生成する.

質問誘導プロンプト A 現在の対話の文脈を目標質問に少し近づける 1 発話目の誘導を行うプロンプト

質問誘導プロンプト B 現在の対話の文脈を目標質問に大きく近づける 2 発話目の誘導を行うプロンプト

質問誘導プロンプト C 現在の対話の文脈から目標質問を尋ねる 3 発話目のプロンプト

そして, 2 つ目の方針に基づき, 各プロンプトでは CoT を用いて, 質問誘導に必要な推論過程を明示的に出力させる. 本研究では, 質問誘導に必要な推論過程を, 「目標質問を尋ねる話の流れになっているか」, 「現在は何についての話か」, 「目標質問は何についての質問か」, 「どうすれば自然に目標質問を尋ねることができるか」という 4 つの項目に整理し, これら 4 つの項目を出力させる指示をプロンプトに含める. また, 一般的に, プロンプトに具体例を含めることでタスク性能が向上することが知られており (Brown et al. 2020), これは CoT の場合でも同様とされる (Kojima et al. 2022). そこで, 本研究でも, 途中の思考まで含めた理想的な誘導および質問例をショットとしてプロンプトに含める. このショットには, 研究室内で別途収集した人間同士の質問誘導対話において, 誘導が自然であった対話を著者が厳選し, 途中の思考である 4 項目についても著者が人手で作成したものを使用する.

図 3 に CoT を使った質問誘導プロンプト C の具体例を示す. このプロンプトでは, 「あなたはバーで飲みすぎて失敗したことはありますか?」を目標質問とした誘導例をショットとして含めている. 質問誘導プロンプト A, B の具体例については, 付録の図 10 および図 11 を参照されたい.

3.2 応答と選択肢の対応づけ

質問に対する応答から、紙面アンケートと同じ形式の回答を取得するには、得られた応答をその質問で定められた選択肢に対応づける必要がある。しかし、質問に対して明確な回答を行っていない応答や、選択肢とは全く異なる表現で回答している応答も存在しうするため、単純な文字列ベースのパターンマッチングによって対応づけを行うことは困難だと考えられる。

そこで、本研究では、LLM を用いて、得られた応答をその質問で定められた選択肢に対応づける。本研究で用いるプロンプトを図 4 に示す。プロンプトには質問文、選択肢、応答文の 3 つを含め、回答有無の判定と対応づけを行うように指示を与えている。また、応答には誤字や省略等が含まれる可能性についてプロンプトに記述している。これにより、そのような場合においても LLM が必要な情報を補完して、適切な対応づけが行われることを期待する。

3.3 アンケート対話システム

本研究では、質問誘導と応答と選択肢の対応づけを組み合わせることで、アンケート対話システムを構築する。本システムとの対話の流れについて説明する。本研究では、どのような文脈からでも、指定のターンで指定の質問が確実に尋ねられることを重視し、質問を尋ねるターンと尋ねる質問は対話開始時に指定する。対話開始後、本システムは、まずは単に雑談を行うように指示を与えたプロンプトを用いて雑談を行う。そして、指定したターンになると、質問誘導が始まり、誘導を行った後に質問を尋ねる。質問を尋ねた後は、再び雑談を行う。これにより、対話全体としては雑談を行いつつ、その一部で質問誘導を行うことで、アンケートに含まれる質問の回答を収集する。また、対話の中で得られた質問に対する応答は、対話終了後に、3.2 節で述べた応答と選択肢の対応づけによってアンケート形式の回答へと変換される。

4 クラウドソーシング実験

アンケート対話システムの質問誘導能力と、システムによって得られるアンケート回答の品質について、評価実験を行った。なお、本節および 5 節で説明する実証実験を含む本研究でのすべての実験の実施にあたっては、所属機関において、倫理面に関する審査を経ている。

4.1 一般的な質問を対象とした質問誘導能力の対話者自身による評価実験

本質問誘導の妥当性を確認するために、まずフレイル以外の一般的な質問を用いて、アンケート対話システムの質問誘導能力の評価を行った。質問誘導能力の評価にあたっては、Horiuchi and Higashinaka (2021, 2023) を参考に、「あなたには仲の良い友達が居ますか？」や「あなたの考えは保守とリベラルどちらですか？」などの、尋ねることが簡単な質問から難しい質問まで

を含む様々なトピックの質問 50 個を用いた。そして、クラウドソーシング¹を介し、システムとクラウドワーカーの質問誘導対話を実施した。

CoT を用いた質問誘導の有効性を検証するため、3.1 節の質問誘導で使用するプロンプトを変えたアンケート対話システムを以下の 2 種類実装した。

gpt-4o 0-shot CoT CoT を用いず、具体例を含めないプロンプトを入力とする gpt-4o²。

gpt-4o CoT 5-shot CoT を用いて、理想的な誘導および質問の具体例を 5 つ含めたプロンプトを入力とする gpt-4o。

本実験には、合計 25 人のクラウドワーカーが参加した。各クラウドワーカーはウェブ上の対話画面で、gpt-4o 0-shot と gpt-4o CoT 5-shot と 2 回ずつ、計 4 回の対話をランダムな順序で行った。クラウドワーカーに提示した対話画面については、付録の図 12 を参照されたい。実験を通して、1 つのシステムあたり 50 回、計 100 回の対話が行われた。各対話の開始にあたり、クラウドワーカーにはファッションやゲームなどの 30 種類の話の中からランダムな話題を 1 つ与え、当該話題から対話を開始するように教示した。システムとクラウドワーカーは交互に 11 回ずつ発話し、システムは自身の 5 発話目から 10 発話目の間でランダムに質問を尋ねた。なお、クラウドワーカーには質問誘導が行われることは伝えなかった。

対話の品質を評価するため、一般的な対話評価に用いられる 5 つの項目 (Chiba and Higashinaka 2025) を用いた対話者自身による評価を行った。各項目の文言を以下に示す。クラウドワーカーは、各対話の終了後に、これら 5 項目をそれぞれ「1. 全く当てはまらない」から「5. 非常によく当てはまる」の 5 段階で評価した。

- **対話自然性** 対話システムの応答は対話として自然だった
- **対話理解度** 対話システムはこちらの発話を適切に理解していると感じた
- **対話一貫性** 対話システムの応答は矛盾せず一貫していた
- **対話興味度** 自分は、今回の対話で話した話題に興味がある
- **対話満足度** 自分は、今回の対話に満足した

また、質問の自然性を評価するため、すべての対話終了後、クラウドワーカーは以下の 1 つの項目に対して、「1. 全く当てはまらない」から「5. 非常によく当てはまる」の 5 段階に「0. 質問が行われていない」を追加した 6 段階で評価した。

- **質問自然性** 誘導から目標質問までを行っている 3 ターンの対話では、目標質問が自然な話の流れで行われた

この項目の評価をすべての対話終了後としたのは、本実験の目的が質問を自然に尋ねることであり、その意図を陽にクラウドワーカーに示さないようにするためである。

¹ <https://crowdworks.jp/>

² gpt-4o-2024-08-06 を用いた

システム	対話 自然性	対話 一貫性	対話 理解度	対話 興味度	対話 満足度	質問 自然性
gpt-4o 0-shot	3.74 (0.82)	3.90 (0.78)	4.00 (0.87)	3.24 (0.99)	3.68 (0.86)	2.26 (1.07)
gpt-4o CoT 5-shot	3.82 (0.86)	3.86 (1.10)	3.90 (0.98)	3.22 (0.97)	3.52 (1.04)	3.16 (1.20)*

表 1: 一般的な質問を対象とした質問誘導対話に対する対話者自身による評価結果. 括弧内は標準偏差である. * は gpt-4o 0-shot との有義差が $p < .01$ であることを示す.

表 1 に評価結果を示す³. 比較手法の有義差を判定するための統計検定には Mann-Whitney の U 検定 (Mann and Whitney 1947) を用いた. 表 1 を見ると, 質問自然性では, gpt-4o CoT 5-shot が gpt-4o 0-shot を有意に上回る結果となり, 質問誘導における CoT プロンプトの有効性が確認された. また, 対話自然性や対話一貫性などの対話の質に関する評価においては, gpt-4o 0-shot と gpt-4o CoT 5-shot でほとんど差はなく, どちらも 5 段階評価で 4.0 前後の値となった. このことから, 質問誘導が行われていても, 全体的な対話の質は維持されていることが確認された.

4.2 一般的な質問を対象とした質問誘導能力の第三者評価実験

ここまで述べてきた対話者自身による評価は, 質問誘導が適切に行われていたかを直接評価するものではない. そこで, 質問が適切に誘導されていたかを評価する実験を別途クラウドソーシングにて実施した. また, 人間の質問誘導性能と比較するため, 4.1 節で収集した 100 件の質問誘導対話に加え, 研究室で別途収集した人間同士の質問誘導対話において, システムが行った質問と同じ質問が用いられた 50 対話を含めた合計 150 対話の評価対象とした. この人間同士の質問誘導対話は, Horiuchi and Higashinaka (2023) において, 特定の質問を自然に尋ねるように指示をされた話者の対話を収集した Question-Guiding Corpus (QGC) と同様の方針で収集されたものである. 本評価には 30 人のクラウドワーカが参加し, 1 つの対話当たり 3 人が評価を行った. クラウドワーカに提示した対話の評価画面については, 付録の図 13 を参照されたい. クラウドワーカには目標質問までの対話を提示し, 対話の自然性や誘導発話の有効性を評価する以下の 7 つの項目への回答を求めた.

- **対話自然性** 誘導から目標質問までを行っている 3 ターンの対話は, 対話として自然である
- **目標質問の有無 (1 回目)** 1 回目の誘導発話に目標質問が含まれている
- **目標質問の有無 (2 回目)** 2 回目の誘導発話に目標質問が含まれている

³ gpt-4o CoT 5-shot の 1 件の対話において, 質問自然性のクラウドワーカからの回答が「0. 質問が行われていない」となっていた. 著者が目視でシステムの発話を確認したところ, 質問は正しく行われていたため, 質問自然性の評価はこの回答を除外して行った.

質問者	対話自然性	誘導有効性 (1 回目)	誘導有効性 (2 回目)	質問自然性
a. Human	3.37 (1.21) ^b	2.73 (1.28)	3.10 (1.26)	3.29 (1.39) ^b
b. gpt-4o 0-shot	2.99 (1.19)	2.68 (1.16)	3.03 (1.22)	2.86 (1.35)
c. gpt-4o CoT 5-shot	3.45 (1.19)^{bb}	3.16 (1.14)^{aa,bb}	3.65 (1.02)^{aa,bb}	3.46 (1.31)^{bb}

(a) 対話自然性, 誘導有効性 (1 回目), 誘導有効性 (2 回目), 質問自然性の評価結果. 括弧内は標準偏差である. 数字の上付き文字 a-c は, その値が上付き文字で示される質問者の値よりも統計的に優れていることを示す. 二重文字 (aa, bb) は $p < .01$, それ以外は $p < .05$ を意味する.

質問者	目標質問の有無 (1 回目)	目標質問の有無 (2 回目)	目標質問の有無 (3 回目)
a. Human	0.093 (14 / 150)	0.100 (15 / 150)	0.953 (143 / 150)
b. gpt-4o 0-shot	0.107 (16 / 150)	0.107 (16 / 150)	0.907 (136 / 150)
c. gpt-4o CoT 5-shot	0.107 (16 / 150)	0.180 (27 / 150)	0.913 (137 / 150)

(b) 目標質問の有無 (1 回目), 目標質問の有無 (2 回目), 目標質問の有無 (3 回目) の評価結果. 表中の値は, すべてのクラウドワーカの回答における「1. はい」の割合である.

表 2: 質問誘導対話データに対する第三者評価結果

- **目標質問の有無 (3 回目)** 質問発話に目標質問が含まれている
- **誘導有効性 (1 回目)** 1 回目の誘導発話のおかげで目標質問が尋ねやすくなっている
- **誘導有効性 (2 回目)** 2 回目の誘導発話のおかげで目標質問が尋ねやすくなっている
- **質問自然性** 質問発話は, 目標質問を自然な流れで尋ねている

クラウドワーカは, 目標質問の有無 (1 回目), 目標質問の有無 (2 回目), 目標質問の有無 (3 回目) の 3 項目に対しては「1. はい」および「2. いいえ」の 2 段階で評価し, 対話自然性, 誘導有効性 (1 回目), 誘導有効性 (2 回目) の 3 項目に対しては「1. 全く当てはまらない」から「5. 非常によく当てはまる」の 5 段階で評価した. そして, 最後の質問自然性に対しては, 「1. 全く当てはまらない」から「5. 非常によく当てはまる」の 5 段階に「0. 質問が行われていない」を追加した **6 段階**で評価した. ここで, 目標質問の有無について尋ねている理由は, システムが 1 回目および 2 回目の誘導発話で誤って目標質問を尋ねてしまった対話や, 目標質問を尋ねる 3 発話目で目標質問を尋ねなかった対話という, 想定とは異なる挙動をしてしまった対話を発見するためである.

表 2 に評価結果を示す⁴. ~~比較手法の有意差を判定するための統計検定には Steel-Dwass の多~~

⁴ gpt-4o 0-shot の 4 件, gpt-4o CoT 5-shot の 4 件, Human の 1 件において, 質問自然性のクラウドワーカからの回答が「0. 質問が行われていない」となっていた. また, 目標質問の有無 (3 回目) において, 「2. いいえ」, すなわち質問が行われていないと回答したのにも関わらず, 質問自然性において「0. 質問が行われていない」以外を選んでいるケースが 25 件存在した. 著者が目視でそれらのシステムの発話を確認したところ, 質問はすべて正しく行われていたため, 質問自然性の評価は「0. 質問が行われていない」の回答を除外して行った.

目標質問	誘導発話
あなたは浪人して大学に入りましたか？	近所の景色って、どんな雰囲気なんですか？自然が多い場所ですか？
あなたは人種差別についてどのような考えをお持ちですか？	その小説の中で、人種差別のようなテーマについて触れられている部分はありましたか？

表 3: 目標質問を含んでいると判断された誘導発話の例

重比較検定 (Dwass 1960) を用いた。表 2(a) から, gpt-4o CoT 5-shot と gpt-4o 0-shot を比較すると, gpt-4o CoT 5-shot はすべての項目で有意に高いスコアを示した。gpt-4o CoT 5-shot は, Human との比較においてもすべての項目で高いスコアを示し, 誘導有効性 (1 回目) および誘導有効性 (2 回目) では有意に優れていた。この結果は, CoT を用いることで, 適切に対話を誘導し, 自然に質問を尋ねることが可能であることを示している。Human の質問自然性が高くなかった理由としては, 質問誘導には一定のスキルが必要であり, 人間であっても適切な誘導が困難な場合があるためだと考えられる。

表 2(b) の目標質問の有無を見ると, どのシステムでも, 目標質問の有無 (1 回目) および目標質問の有無 (2 回目) において, 「1. はい」, すなわち目標質問を含んでいるという回答が 10% 程度存在した。表 3 にそのような回答が行われた誘導発話の具体例を示す。目標質問「あなたは浪人して大学に入りましたか？」と誘導発話「近所の景色って、どんな雰囲気なんですか？自然が多い場所ですか？」は, 明らかに異なる意味の発話である。また, 目標質問「あなたは人種差別についてどのような考えをお持ちですか？」と誘導発話「その小説の中で、人種差別のようなテーマについて触れられている部分はありましたか？」は, 話題は類似しているが, 目標質問とは異なる意味の発話である。これらのように, 明らかに目標質問とは異なる意味の発話や, 話題は類似しているが, 目標質問とは異なる意味の発話において, 目標質問が含まれていると回答されていた。著者が目視で確認する限りでは, 目標質問と完全に同じ意味の誘導発話は存在しなかった。

表 4 に, システムごとの, 誘導から目標質問までを行った 3 ターンの各発話の統計量を示す。表 4 を見ると, すべての発話において, gpt-4o 0-shot は最も文字数が多いことがわかる。また, 誘導発話 (1 回目) および誘導発話 (2 回目) においては, Human の発話が最も文字数が少ない一方で, 質問発話においては gpt-4o CoT 5-shot が最も文字数が少なかった。これは, gpt-4o CoT 5-shot では, 誘導発話により質問を自然に尋ねるための文脈を適切に形成できており, 質問を尋ねる発話自体は少ない文字数で自然に尋ねることができていた可能性を示唆している。

表 5 に各システムの質問自然性が高かった対話例を示す。表 5(a) の Human の対話は, 表 5(b) の gpt-4o 0-shot の対話および表 5(c) の gpt-4o CoT 5-shot の対話よりも少ない文字数の発話で

質問者	発話	文字数	単語数
Human	誘導発話 (1 回目)	48.96 (20.00)	30.82 (12.96)
	誘導発話 (2 回目)	49.26 (19.41)	30.14 (11.78)
	質問発話	64.04 (18.54)	40.76 (11.58)
gpt-4o 0-shot	誘導発話 (1 回目)	64.36 (19.18)	38.97 (11.18)
	誘導発話 (2 回目)	62.67 (16.32)	38.64 (10.46)
	質問発話	79.26 (26.93)	49.03 (16.63)
gpt-4o CoT 5-shot	誘導発話 (1 回目)	59.14 (14.48)	35.84 (8.55)
	誘導発話 (2 回目)	50.92 (12.62)	32.30 (8.08)
	質問発話	56.46 (10.77)	35.95 (6.19)

表 4: システムごとの各発話における文字数および単語数. 括弧内は標準偏差である. 単語分割には UniDic 辞書を適用した MeCab を利用した.

誘導を行っているが, どのシステムも自然に質問を尋ねるための文脈を形成した後に質問を尋ねていることがわかる. 一方で, 表 6 に質問自然性が低かった対話例を示す. 表 6(a) の Human の対話および表 6(b) の gpt-4o 0-shot の対話では, 質問を尋ねるための誘導を行えておらず, 突然質問を尋ねてしまっている. このような対話が一定数存在したことが, 誘導有効性 (1 回目) および誘導有効性 (2 回目) の低下につながったと考えられる. また, 表 6(c) の gpt-4o CoT 5-shot では, 質問を尋ねる前に, 既に対話相手が質問に対する回答をしてしまっている. 本アンケート対話システムは, 質問するターンを固定しており, 必ず指定したターンで質問を尋ねるため, 既に質問に対する回答が得られていても, 同じことを尋ねる質問を尋ねてしまう. この問題の改善には, 1 発話ごとに目標質問に対する回答が対話履歴に含まれるかを確認し, 含まれる場合には質問をスキップする, といった動的な制御が必要だと考えている. **こちらについて**は今後の課題としたい.

4.3 フレイルアンケートを対象とした質問誘導能力と回答品質の評価

~~ここまでの実験を通して, 一般的な質問を対象とした場合のアンケート対話システムの有効性を確認することができた.~~ 続いて, 本研究の目的である **フレイルアンケート**を対象とした質問誘導対話をクラウドソーシングを介して実施し, **フレイルアンケート**での質問誘導能力の評価を行った. この評価は, 4.1 節で実施した対話者自身による評価実験と同様の手順で行った. また, アンケート対話システムによって得られる回答の品質を検証するため, アンケート対話システムを用いて収集したアンケートの回答と, 紙面アンケートによって直接得られた回答との一致率を評価した. アンケートに含める質問としては, 「お茶や汁物等でむせることがありますか? (はい, いいえ)」や「自分には人との付き合いがないと感じることがありますか? (決してない, ほとんどない, 時々ある, 常にある)」などの, フレイルを判定するための質問 22

ユーザ: ちゃんと買い替えているなら、清潔感ある感じで良いですね！
 システム: ファッションはプチプラ派ですが、食べ物にはお金をかけてしまいがちかもです。そういうのありますか？
 ユーザ: パソコン周りにはお金をかけている方かもしれません。
 システム: そうなんですね！パソコン関係で一番高いのは何ですか？
 ユーザ: パソコン本体ですが、近々、外付けの大容量バッテリーを買おうと思っているので、それが一番高くなりそうです！
 システム: それは高そうですね。あなたはお金を借りて何かを買った経験はありますか？

(a) Human の質問誘導対話例。質問自然性は 4.00.



ユーザ: プライベートブランドのものが安くてお得なのでよく買っているかな。最近色々高いからさ。
 システム: (誘導プロンプト A を利用) プライベートブランドはコスパが良いですよ。最近、特に値上がりを感じる商品ってありますか？
 ユーザ: ヨーグルト。昨年までは百円しなかったのに、最近百二十円ぐらいになってる。
 システム: (誘導プロンプト B を利用) それは結構な値上がりですね。物価が上がると、家計のやりくりも大変ですよ。大きな買い物をするとき、どんな工夫をしていますか？
 ユーザ: 野菜や肉や果物は鮮度が大事なのでスーパーでしか買わないけど、家電なんかは楽天やヨドバシのほうがポイント還元があったりしてお得なのでそっちを使うことが多いかな。
 システム: (誘導プロンプト C を利用) 家電を買うときにポイント還元があると嬉しいですよ！そのような大きな買い物をするとき、お金を借りて何かを買った経験はありますか？

(b) gpt-4o 0-shot の質問誘導対話例。質問自然性は 3.67.

ユーザ: リラックスするために、なるべく仕事のことを思い出さないようにしていますね
 システム: (誘導プロンプト A を利用) なるほど。買い物でストレスを解消することもありますか？
 ユーザ: 最近、物価が高いから、買い物もストレスがたまりやすいです
 システム: (誘導プロンプト B を利用) それは困りますね。たまには思い切って少し高価なものを買ってみるのでもいいかもしれませんね。最近、大きな買い物をしたことはありますか？
 ユーザ: クリスマスに少し高めのおもちゃを買って子供にプレゼントしました
 システム: (誘導プロンプト C を利用) クリスマスのプレゼントは特別ですね。私も昔、どうしても欲しいものがあってお金を借りて買ったことがあります。あなたはお金を借りて何かを買った経験はありますか？

(c) gpt-4o CoT 5-shot の質問誘導対話例。質問自然性は 5.00.

表 5: 質問自然性が高かった質問誘導対話例。太字は目標質問を示す。

種 (村瀬 他 2002; Wilson et al. 2005; 舩田 他 2012; 佐竹 2018; Hayashi et al. 2026) (以下、フレイル質問と呼ぶ) を対象とした。表 7 にすべての質問と選択肢を示す。

本実験には、合計 66 人のクラウドワーカーが参加した。各クラウドワーカーは、gpt-4o CoT 5-shot と gpt-4o 0-shot と 1 回ずつ、計 2 回の対話をランダムな順序で行った。その結果、1 つのシス

ユーザ: うわぁ、ご当地アイスなんて最高ですね。ほんとに楽しそう！私はやるなら、カニとか海鮮のものを頼みたいです。

システム: 海鮮ものも良いですね！普通に頼むと、送料がかかってしまうものも、返礼品だと送料込みらしいので、海鮮ものは冷蔵便だしピッタリだと思います。

ユーザ: そうなんです！手続きは簡単なんじゃないかな？

システム: 色んなサイトがふるさと納税の参加を宣伝していますよね。専用のサイトがあるということは、たぶんそこまで難しくはないはずなんですけど、どうなのでしょう。

ユーザ: ちゃんと調べて、一度やってみたら、意外と簡単なのかもしれませんね。！

システム: そうですね。そういうの、詳しくわかるような人になりたいです。**あなたはどんな人がタイプですか？**

(a) Human の質問誘導対話例。質問自然性は 1.00.

ユーザ: そうなんです。たった六分でも毎日はいんどい。

システム: (誘導プロンプト A を利用) それでも続けているのはすごいですね。モチベーションを保つために何か特別な方法がありますか？

ユーザ: 格好いい体になりたいという思いがあるので、それがモチベーションアップになっています。

システム: (誘導プロンプト B を利用) それは素晴らしい目標ですね。心身ともに健康でいることは大切ですね。健康以外にも大切にしていることはありますか？

ユーザ: お金の無駄遣いをしないということです。お金は大事です。

システム: (誘導プロンプト C を利用) それは賢明な考えですね。お金を大切にするのは現代社会で重要なスキルですね。他にも何か大事にしている価値観や信じていることはありますか？**あなたの信仰している宗教は何ですか？**

(b) gpt-4o 0-shot の質問誘導対話例。質問自然性は 2.00.

ユーザ: 主人公のフリーレンが凄い魔法使いですが、どこか落ち着いているかなと思っていたら、結構ドジなところがあり、彼女の周囲の人たちも個性的なところが良いと思います。

システム: (誘導プロンプト A を利用) フリーレンのキャラクターたちの個性が魅力的なんですね。学校の先生やキャラクターの中にも、そういう個性的な人っていますよね。あなたの学校にはどんな先生がいましたか？

ユーザ: 真面目な人が多かったと思います。特別ユニークな人はいませんでした。

システム: (誘導プロンプト B を利用) そうなんです。真面目な先生が多いと安心感がありますよね。でも、時には合わない先生もいたりしますよね。

ユーザ: 確かに、何でも分かりませんが、合わない先生はいましたね

システム: (誘導プロンプト C を利用) そうなんです。あなたの学校で合わない先生はいましたか？

(c) gpt-4o CoT 5-shot の質問誘導対話例。質問自然性は 2.67.

表 6: 質問自然性が低かった質問誘導対話例。太字は目標質問を示す。

テムあたり 66 回、計 132 回の対話が行われた。各対話の開始にあたり、クラウドワークにはファッションやゲームなどの 30 種類の話題の中からランダムな話題を 1 つ与え、当該話題から

質問文	選択肢
現在の暮らしの状況について、経済的にみてどう感じていますか？	ゆとりがある/ややゆとりがある/ふつう/やや苦しい/苦しい
同居されている方はどなたですか？	自由記述
あなたの心配ごとや愚痴を聞いてくれる人はいますか？	はい/いいえ
友達の家を訪ねることがありますか？	はい/いいえ
昨年と比べて外出の回数は減っていますか？	とても減っている/減っている/あまり減っていない/減っていない
どのような社会参加活動に参加していますか？	複数選択：ボランティアグループ/高齢者クラブ（老人クラブ）/健康体操やサロンなどの介護予防のための通いの場（地域サロン）/町内会・自治会活動/学習・教養サークル/スポーツや運動のグループ・クラブ/趣味活動/地域の伝統や文化を伝える活動/収入のある仕事
あなたは現在住んでいる地域にどの程度愛着がありますか？	とても愛着がある/まあ愛着がある/どちらともいえない/あまり愛着がない/全く愛着がない
階段を手すりや壁をつたわずに昇っていますか？	はい/いいえ
1 km ぐらいの距離を続けて歩くことができますか？	はい/いいえ
1日のうち、座っているまたは横になっている時間は、起きている時間の8割以上ですか？	はい/いいえ
気分が沈み込んで、何が起ころうとも気が晴れないように感じましたか？	はい/いいえ
何をするのも骨折りだと感じましたか？	いつも/たいてい/ときどき/少しだけ/全くない
食欲はありますか？	まったくない/ない/ふつうだ/ある/とてもある
食事をとるとき満腹になりますか？	数口食べるだけで満腹になる/3分の1ほど食べると満腹になる/半分ほど食べると満腹になる/ほとんど食べれば満腹になる/満腹になることはほとんどない
食べ物の味が美味しいと感じますか？	とてもまずいと感じる/まずいと感じる/ふつうだと感じる/おいしいと感じる/とてもおいしいと感じる
普段の食事は何回とりますか？	1日1回もとらない/1日1回とる/1日2回とる/1日3回とる/1日4回以上とる
半年前に比べて固いものが食べにくくなりましたか？	はい/いいえ
お茶や汁物等でむせることがありますか？	はい/いいえ
口の渇きが気になりますか？	はい/いいえ
自分には人との付き合いがないと感じることがありますか？	決してない/ほとんどない/時々ある/常にある
自分は取り残されていると感じることがありますか？	決してない/ほとんどない/時々ある/常にある
自分は他の人たちから孤立していると感じることはありますか？	決してない/ほとんどない/時々ある/常にある

表 7: フレイルを判定するための質問 22 種の質問文と選択肢

対話を開始するように教示した。対話はシステムとクラウドワーカが交互に 20 回ずつ発話し、システムは 6 発話から 9 発話に 1 度の間隔で、1 対話あたり 2 つの質問を尋ねた。そして、すべての対話終了後、クラウドワーカは対話内で尋ねられた質問と同じ項目のアンケートへの回

システム	対話 自然性	対話 一貫性	対話 理解度	対話 興味度	対話 満足度	質問 自然性
gpt-4o 0-shot	4.38 (0.60)	4.34 (0.73)	4.42 (0.66)	3.81 (0.79)	4.19 (0.81)	3.23 (1.14)
gpt-4o CoT 5-shot	4.19 (0.73)	4.27 (0.76)	4.38 (0.78)	3.80 (0.79)	4.05 (0.84)	3.59 (1.06)*

表 8: フレイルを対象とした質問誘導対話に対する対話者自身による評価結果. 括弧内は標準偏差である. * は gpt-4o_0-shot との有義差が $p < .01$ であることを示す.

答を行った. 実験全体を通して, 22 種の質問はそれぞれ 12 回ずつ行われたため, 対話の中で得られた質問に対する応答と, アンケートによって得られた回答のペアが合計 264 組収集された. ここで, これらの応答は, 3.2 節で述べた応答と選択肢の対応づけにより, 適切な選択肢に対応づける. ただし, 評価の簡単化のため, この対応づけと一致率の評価においては, 「同居されている方はどなたですか?」という自由記述質問 1 種と, 「どのような社会参加活動に参加していますか?」という複数選択質問 1 種の計 2 種の質問は除外し, その他 20 種の単一選択質問のみの 240 組を対象とした. 対応づけを行うモデルには gpt-4o を利用した.

gpt-4o を用いた応答と選択肢の対応づけの性能を評価するため, 人手による対応づけを実施した. 本実験には 12 人のクラウドワーカーが参加し, 1 つの質問と応答ペア当たり 3 人が対応づけを行った. この対応づけは, ユーザの発話内容に最も当てはまる選択肢を判断するものであり, 医学的知識は必要ない. そのため, 一般のクラウドワーカーによる評価を行った. クラウドワーカーに提示した評価画面については, 付録の図 14 を参照されたい. 各クラウドワーカーには質問とそれに対する応答が提示され, その応答に該当する選択肢への対応づけを行った. この際, 質問に対する応答の品質を詳細に分析するため, 明示的な回答が含まれている応答, 暗黙的な回答が含まれている応答などの 5 種類の応答タイプへの分類も行った (詳細は 5.4 節で述べる). ここで, 2 人以上の選択肢が一致した場合に限り, その選択肢をその応答の代表選択肢として扱い, 一致率の計算に利用した. 3 人とも異なる選択肢であった場合は, 回答を判断できない無効な応答として扱った.

表 8 に対話者自身による評価の結果を示す. 比較手法の有義差を判定するための統計検定には Mann-Whitney の U 検定を用いた⁵. 表 8 を見ると, 質問自然性では, gpt-4o CoT 5-shot が gpt-4o 0-shot を有意に上回る結果となり, フレイル質問を対象とした場合においても, 質問誘導における CoT プロンプトの有効性が確認された. また, 対話自然性や対話一貫性などの対話の質に関する評価においては, gpt-4o 0-shot と gpt-4o CoT 5-shot でほとんど差はなく, どちら

⁵ gpt-4o 0-shot の 2 件, および gpt-4o CoT 5-shot の 1 件の対話において, 質問自然性のクラウドワーカーからの回答が「0. 質問が行われていない」となっていた. 著者が目視でシステムの発話を確認したところ, 質問は正しく行われていたため, 質問自然性の評価はこれらの回答を除外して行った.

対応づけ手法	評価方法	選択肢 2 つ	選択肢 4 つ	選択肢 5 つ	全体
gpt-4o	完全一致	0.737 (70 / 95)	0.476 (20 / 42)	0.667 (46 / 69)	0.660 (136 / 206)
	部分一致	—	0.786 (33 / 42)	0.870 (60 / 69)	0.791 (163 / 206)
Human	完全一致	0.840 (79 / 94)	0.487 (19 / 39)	0.652 (45 / 69)	0.708 (143 / 202)
	部分一致	—	0.795 (31 / 39)	0.855 (59 / 69)	0.837 (169 / 202)

(a) 無効な回答を分母に含まない場合

対応づけ手法	評価方法	選択肢 2 つ	選択肢 4 つ	選択肢 5 つ	全体
gpt-4o	完全一致	0.648 (70 / 108)	0.417 (20 / 48)	0.548 (46 / 84)	0.567 (136 / 240)
	部分一致	—	0.688 (33 / 48)	0.714 (60 / 84)	0.679 (163 / 240)
Human	完全一致	0.731 (79 / 108)	0.396 (19 / 48)	0.536 (45 / 84)	0.596 (143 / 240)
	部分一致	—	0.646 (31 / 48)	0.702 (59 / 84)	0.704 (169 / 240)

(b) 無効な回答を分母に含む場合

表 9: クラウドソーシングでの対話で得られた回答とアンケートで得られた回答の一致率.

も 5 段階評価で 4.0 前後の値となった. このことから, フレイル質問を対象とした質問誘導においても, 全体的な対話の質は維持されていることが確認された.

表 9 に gpt-4o と人手の対応づけ結果を示す. 表 9(a) は, 無効な回答を分母に含めず, 一致率の計算から除外した値, 表 9(b) は, 無効な回答を分母に含め, 一致率の計算に含めた値である. ここで, これらの回答の一致率は, 選択肢の数ごとに分けて算出した. また, 選択肢が 4 つと 5 つの質問に対しては, 選択肢との完全一致に加え, 隣接する選択肢間のずれを許容する評価 (以下, 部分一致と呼ぶ) も行った. これは, 対応づけ結果を評価する際に, 尺度上で大きく異なる選択肢への誤対応と, 隣接する選択肢への軽微なずれとを区別して把握するためである. 具体的には, 選択肢が 4 つの質問では, 先頭 2 つの選択肢を統合し, 後尾 2 つの選択肢も統合することで 2 つの選択肢として評価した. 例えば, 選択肢が「とても減っている, 減っている, あまり減っていない, 減っていない」であれば, 「減っている, 減っていない」とみなして評価した. 選択肢が 5 つの質問では, 先頭 2 つの選択肢を統合し, 中央 1 つの選択肢はそのまま残し, 後尾 2 つの選択肢を統合することで, 3 つの選択肢として評価した. 例えば, 選択肢が「ゆとりがある, ややゆとりがある, ふつう, やや苦しい, 苦しい」であれば, 「ゆとりがある, ふつう, 苦しい」とみなして評価した. このため, 例えば対応づけ結果が「ゆとりがある」でアンケートの回答が「ややゆとりがある」のような場合でも一致とした.

表 9(a) 上段の gpt-4o の対応づけ結果を見ると, 全体での完全一致率は 0.660 と改善の余地はあるが, 部分一致率では 0.791 と比較的高い一致率が得られ, アンケート対話システムがアンケートと類似した回答を得られることがわかった. また, 表 9(a) 下段の人手の対応づけ結果と

質問	応答	選択肢	アンケート回答
友達の家を訪ねることがありますか？	一切ないです、面倒なので	はい/いいえ	はい
普段の食事は何回とりますか？	一日に2回か3回です。 朝は食べたり食べなかったりです。	1日1回もとらない/1日1回とる/1日2回とる/1日3回とる/1日4回以上とる	1日3回とる

表 10: 正しい対応づけが困難な例

比較すると、人手の対応づけは gpt-4o の対応づけよりも高い一致率となったが、その差は完全一致率、部分一致率ともにわずか 4%程度であり、gpt-4o は人手に匹敵する精度での対応づけが可能であることが示された。一方で、表 9(b) の無効な回答を一致率の計算に含めた値を見ると、gpt-4o、人手ともに、一致率は 10%以上低下した。これは、無効な回答と判定された応答が、応答全体の 10%以上存在したためである。この問題は、無効な回答と判定された場合には同じ質問を繰り返すといった仕組みをシステムに導入することで、改善される見込みがある。

続いて、人手での対応づけに失敗した応答について分析する。表 10 にそのような応答の具体例を示す。上段の「友達の家を訪ねることがありますか？」という質問では、「一切ないです、面倒なので」という否定の応答がされていたが、アンケートの回答は肯定の「はい」であった。また、下段の「普段の食事は何回取りますか？」という質問では、「一日に2回か3回です。」という1つの選択肢に決定できない応答がされていた。これらの具体例のように、アンケートの回答と明らかに異なる選択肢に該当する応答や、1つの選択肢に決定できない曖昧な応答など、人手でも正しく対応づけることが困難な応答が存在した。この問題の改善には、曖昧な応答に対しては深掘り質問を行うなど、より適切な回答を得るための対話戦略が必要だと考えている。こちらについては今後の課題としたい。

5 高齢者を対象とした実証実験

ここまでの実験を通して、テキスト対話におけるアンケート対話システムの有効性を確認することができた。しかし、実際にフレイルアンケートの回答をすべて収集するには、長期間、日常的にアンケート対話システムと対話する必要がある。また、ユーザである高齢者にとって、テキスト対話は負担が大きいため、システムとは音声で対話できることが望ましい。そこで、音声対話における実環境でのアンケート対話システムの有効性を検証するため、高齢者が自宅でアンケート対話システムと2週間対話する実証実験を実施した。本実験では、4.3節で使用したフレイルアンケートを対象とした。




図 5: Amazon Echo Show の対話画面




図 6: 実験参加者が対話システムと対話している様子

5.1 対話システムの構成

本実験では、3 節で説明したアンケート対話システムを内部に組み込んだ音声対話システムを開発し、使用した。~~この音声対話システムの詳細について説明する。~~本対話システムは、音声対話を行うため、音声対話端末である Amazon Echo Show 上に実装した。そして、親しみやすいキャラクターとして大学生のペルソナを付与した (吉田麻里子 他 2025; Yoshida et al. 2025)。図 5 に Amazon Echo Show の対話画面を、図 6 に実験参加者が本対話システムと対話している様子を示す。図 5 の Amazon Echo Show の画面にあるように、対話時にはキャラクターのイラストが表示され、システムの発話に応じて上下に動作する。音声認識と音声合成には Amazon Alexa Skills 上で提供されている機能を使用した。

~~本システムを用いた対話の流れについて説明する。~~本システムは、6 から 9 ターンに 1 度 gpt-4o CoT 5-shot を用いて質問誘導を行い、それ以外では API 費用を抑えるため gpt-4o-mini を用いて雑談を行う。図 7 にシステムの 1 発話目の生成に使用するプロンプトを、図 8 に 2 発話目以降の雑談生成に使用するプロンプトを示す。~~これらの図に示すように、雑談時には、以下の 3 つの情報を考慮して発話を生成する。~~

- **システムのペルソナ情報** キャラクタの名前や性別、性格などの固定の情報に加え、キャラクターの毎日の予定を含めている。図 9 に具体的な設定を示す。
- **ユーザ情報** 実験参加者であるユーザの名前、および直近の最大 7 件までの対話を含めている。ユーザの名前は事前に登録される。
- **ニュース情報** **NHK ニュースのトップページ**⁶に含まれるすべてのニュースの見出しを自動で収集し、収集した時刻と併せて含めている。ニュースの収集は 1 日 4 回、定期的に

⁶ <https://www3.nhk.or.jp/news/>

```
chatbot character details:
{character_details}

user information:
{user_info}

Recent news titles:
{news_titles}

you are the chatbot character.
say hello to the user in japanese in under 30 tokens, but also add an appropriate conversation topic from above.
極力ラフな敬語で話してください。時間に合わせた挨拶を行って。
please note that the user cannot see the news.
if there are past topics that you wish to follow up on, ask about it.
you may ask the user how they are feeling today or what they are up to today.
```

図 7: システムの 1 発話目の生成プロンプト. {character_details} にはシステムのペルソナ情報, {user_info} にはユーザ情報, {news_titles} にはニュース情報が入る.

```
Chatbot character details:
{character_details}

user information:
{user_info}

Conversation log:
{conversation_log}

recent news:
{recent_news}

- Respond to the user speech as the chatbot character in a single sentence, in under 30 tokens.
- speak politely and concisely, but keep the conversation engaging.
- you should not call the user's name very often.
- speak only one sentence.
極力ラフな敬語で話してください。
ユーザとあなたの活動が混同しないよう、キャラクター視点を保ってください。
すでに今日何をするか聞いた場合は、何度も聞かないようにしてください。

User speech:
{user_speech}

現在時刻は{timestamp}なので、それに矛盾がないように答えてください。
```

図 8: システムの 2 発話目以降の雑談生成プロンプト. {character_details} にはシステムのペルソナ情報, {user_info} にはユーザ情報, {conversation_log} には対話履歴, {news_titles} にはニュース情報, {user_speech} には直前のユーザ発話, {timestamp} には JST の現在時刻が入る.

実行した.

また, システム利用を促すため, 1 日 1 問, 健康に関する 3 択クイズを行う機能を実装した. システムは, 雑談時, ユーザの発話中に「クイズ」という文字列が含まれていた場合, 事前に作成されたクイズの問いと選択肢を発話し, 数秒待った後に回答と解説を話す.

あなたは愛知県名古屋で生まれ育った、21歳の女性です。
 名前は、「あいり」です。一人称は、私です。
 職業は学生で、実家から電車で名古屋大学の情報学部に通っています。
 同居家族は両親と3歳離れた弟で、近くに住んでいる祖父母ともよく会います。
 異性愛者ですが、現在彼氏はいません。
 大学ではバレーボールのサークルに入っていて、サークルや学部の同期と仲良しです。
 イタリアンのファミリーレストランでアルバイトをしています。
 友人とは、一緒に勉強したり、ランチを食べに行ったり、カラオケに行ったりします。
 趣味はカフェ巡りと料理と手芸で、好きな音楽ジャンルは懐メロです。
 好きな食べ物はオムライスと豚汁で、苦手な食べ物はきのこニンジンです。
 高校時代の得意な科目は国語で、苦手な科目は化学です。
 非常に明るく、面倒見が良い性格です。
 話を引っ張っていくこともできますが、よく聞き上手だと言われます。
 丁寧な言葉遣いをしますが、誰にでも人懐っこく気楽に話しかけます。
 あなた自身の活動として、あいりちゃんは、昨日は次のようなことをしました：
 {activity_yesterday}
 あいりちゃんは、今日は次のような予定があります：
 {activity_today}
 あいりちゃんは、明日は次のような予定があります：
 {activity_tomorrow}

図 9: システムのペルソナ情報. {activity_yesterday} には昨日の予定, {activity_today} には今日の予定, {activity_tomorrow} には明日の予定が入る.

5.2 実験設定

実験参加者は 65~74 歳の高齢者 6 人と、75 歳以上の高齢者 5 人の計 11 人（全員女性）である。実験参加者は 2 週間の間、1 日 2 回以上本システムと雑談を行った。この間、実験参加者のシステム利用を促すため、メッセージアプリである LINE を通して、1 日 1 回キャラクタからのメッセージの送信を行った。メッセージ内容は、システムのペルソナ情報とユーザとの過去の対話内容を用いて、gpt-4o-mini を用いて生成した。なお、本実験においてフレイル質問を尋ねる旨は参加者には事前に伝えず、実験後におけるヒアリングにおいて伝えることとした。

実験終了後、参加者はフレイルアンケートと、対話システムの評価アンケートへの回答を行った。評価アンケートでは、対話満足度や対話自然性、質問回数について 5 段階の評価を行った。1 日に 3 回以上システムと対話するユーザが多く、実験全体を通して合計 379 回の対話と 5,967 回の発話が行われた。表 11 に実際のシステムと実験参加者との対話例を示す。この対話例では、「普段の食事は何回とりますか？」という目標質問が、自然な誘導発話の後に尋ねられている。

Amazon Alexa Skill の音声認識精度を調査するため、著者 1 人による対話の書き起こしを行い、音声認識結果との比較を行った。書き起こし対象は、11 人の参加者それぞれの対話の中から、参加者が 10 発話以上行った対話を 1 つずつランダムに抽出した計 11 対話とした。11 対話には 151 発話が含まれていた。人手書き起こしの結果、1 発話あたりの平均文字数は 13.1 文字であり、Character Error Rate (CER) は 9.3%, Word Error Rate (WER) は 10.1%であった。表 12 に音声認識誤りの例を示す。全体として、漢字間違いや、発話中の後半部分が認識されて

システム:	こんにちは、{ ユーザ名 }さん！今日はいい天気ですね。お出かけの予定はありますか？ 最近では野菜の値段が上がっているみたいですが、買い物には影響出てますか？
ユーザ:	そうですね野菜は今高いですトマトが高いですキャベツも高いです
システム:	そうなんです、野菜が高いと困りますよね。お料理にはどんな野菜を使いますか？
ユーザ:	キャベツ
システム:	キャベツは新鮮で美味しいですね、何か特別なお料理に使う予定ですか？
ユーザ:	ロールキャベツです
システム:	ロールキャベツ、いいですね！私も大好きです。どうやって作る予定ですか？
ユーザ:	たくさん挽き肉を入れて作ります
システム:	挽き肉たっぷりのロールキャベツ、とても美味しそうですね！どんな味付けをする予定ですか？
ユーザ:	ブイヨンとケチャップです
システム:	(誘導プロンプト A を利用) ブイヨンとケチャップの組み合わせ、絶対美味しいですね！普段からお料理をされるんですか？
ユーザ:	はい毎日してますあირიちゃん料理しますか
システム:	(誘導プロンプト B を利用) はい、私も料理が好きで、特にオムライスを作るのが得意です。普段の食事はどんな感じでされていますか？
ユーザ:	主人と二人で食べています
システム:	(誘導プロンプト C を利用) そうなんです。毎日一緒に食事を楽しむのは素敵ですね。普段の食事は何回とりですか？
ユーザ:	三階です (後略)

表 11: 実証実験での対話例。{ ユーザ名 } には、事前に登録した実験参加者の名前が入る。太字は目標質問を示す。

誤りの種類	人手書き起こし結果	音声認識結果
漢字間違い	週一で筋トレをやっています	秀一で筋トレをやってます
後半なし	そうですねさよならあირიちゃん	そうですねさよなら
フィラーなし	えーっと百パーです	百パーです

表 12: 音声認識誤りの例

いないケース、フィラーが認識されていないケースが多く、ユーザの発話意図を取り違えてしまうような音声認識誤りは少数であった。以上から、Amazon Alexa Skill の音声認識精度には改善の余地があれど、対話品質を損なうことはなかったと考えられる。

最後に、応答から選択肢への対応づけを行った。その結果、対話での回答とアンケートの回答のペアデータが合計 434 個収集された。また、gpt-4o を用いた応答と選択肢の対応づけの性能を評価するため、人手による対応づけを実施した。本対応づけは、本論文の著者 3 人が 4.3 節で説明した対応づけと同様の手順で行い、1 つの質問と応答ペア当たり 3 人が対応づけを行っ

対応づけ手法	評価方法	選択肢 2 つ	選択肢 4 つ	選択肢 5 つ	全体
gpt-4o	完全一致	0.607 (91 / 150)	0.592 (45 / 76)	0.531 (52 / 98)	0.580 (188 / 324)
	部分一致	—	0.842 (64 / 76)	0.786 (77 / 98)	0.716 (232 / 324)
Human	完全一致	0.622 (79 / 127)	0.552 (37 / 67)	0.523 (45 / 86)	0.575 (161 / 280)
	部分一致	—	0.866 (58 / 67)	0.814 (70 / 86)	0.739 (207 / 280)

(a) 無効な回答を分母に含まない場合

対応づけ手法	評価方法	選択肢 2 つ	選択肢 4 つ	選択肢 5 つ	全体
gpt-4o	完全一致	0.460 (91 / 198)	0.495 (45 / 91)	0.359 (52 / 145)	0.433 (188 / 434)
	部分一致	—	0.703 (64 / 91)	0.531 (77 / 145)	0.535 (232 / 434)
Human	完全一致	0.399 (79 / 198)	0.407 (37 / 91)	0.310 (45 / 145)	0.371 (161 / 434)
	部分一致	—	0.637 (58 / 91)	0.483 (70 / 145)	0.477 (207 / 434)

(b) 無効な回答を分母に含む場合

表 13: 実証実験での対話で得られた回答とアンケートで得られた回答の一致率

た. **ここで**, 2 人以上の選択肢が一致した場合に限り, その選択肢をその応答の代表選択肢として扱い, 一致率の計算に利用した. 3 人とも異なる選択肢であった場合は, 回答を判断できない無効な応答として扱った.

5.3 結果分析

表 13 に gpt-4o と人手の対応づけ結果を示す. 表 13(a) は, 無効な回答を分母に含めず, 一致率の計算から除外した値, 表 13(b) は, 無効な回答を分母に含め, 一致率の計算に含めた値である. 表 13(a) 上段の gpt-4o の対応づけ結果を見ると, 全体での完全一致率は 0.580 と低いものの, 部分一致率では 0.716 と比較的高い一致率が得られた. また, 表 13(a) 下段の人手の対応づけ結果と比較すると, 人手は gpt-4o よりも高い一致率となったが, その差は小さく, 実証実験のデータに対しても, gpt-4o は人手に匹敵する精度での対応づけが可能であることが示された. 一方で, 表 13(b) の無効な回答を一致率の計算に含めた値を見ると, 無効な回答が多かったために, gpt-4o は 0.535, 人手は 0.477 と一致率が大きく低下した.

最後に, 対話システム自体の評価アンケート結果について述べる (吉田麻里子 他 2025; Yoshida et al. 2025). 対話満足度では, すべての参加者が「対話は楽しかった」または「対話はとても楽しかった」と回答した. また, 対話自然性では, 過半数の人が「システムの応答は自然だった」と回答しており, 「不自然だった」と回答したのはわずか 1 人のみであった. 質問回数に関しては, 過半数の人が「ちょうどよかった」と回答したが, 一部の参加者は「多かった」と回答していた. 本対話システムは目標質問だけでなく, 一般的な質問も雑談の中で尋ねているため, 全体としては質問を尋ねることが多い対話システムになってしまったことが, 1 つの要因

として考えられる。以上から、本対話システムの対話満足度や対話自然性は高く、本対話システムとの対話の品質に大きな問題はなかったことが確認できた。

5.4 応答内容の分析

対話において、質問に対して必ずしもその回答が得られるとは限らない。特に実生活における音声対話では、意図が曖昧な応答や無関係な応答、あるいは発話が不完全なケースも少なくない。そのような無効な回答がどの程度存在しているのかを把握し、~~アンケート対話システムの今後の改善の方向性を明らかに~~するため、クラウドソーシングと実証実験において収集された質問誘導対話において、アンケートに含まれる質問に対する応答を以下の5種類の応答タイプに分類するアノテーションを実施した。ここで、Sはシステムを表し、Uはユーザを表す。

1. 明示的な応答 質問に対して明確な回答をしている応答

S: 半年前に比べて固いものが食べにくくなりましたか？

U: それはないです

2. 暗黙的な応答 質問に対する明確な回答はしていないが、回答を推論することができる応答

S: 普段の食事は何回とりますか？

U: 朝はコーヒーあとは昼と夜は普通のご飯です

3. 曖昧な応答 質問と関係しているが、回答を推論することができない応答

S: 食べ物の味が美味しいと感じますか？

U: 濃い味付けが好きです

4. 無関係な応答 質問とは全く関係がない応答

S: お茶や汁物等でむせることがありますか？

U: 今日の天気はなんですか

5. 不完全な応答 文章が途中で途切れている、あるいは非文であり、回答を推論することができない応答

S: 1km ぐらいの距離を続けて歩くことができますか？

U: 昨日も夜

クラウドソーシングのデータに対しては12人のクラウドワーカが分類を行い、実証実験のデータは著者3人が行った。アノータータには、質問とそれに対する応答が提示され、その応答に該当する応答タイプへの分類を行った。クラウドソーシングのデータと実証実験のデータともに、1つの質問と応答ペアに対して3人が分類を行った。

アノテーションの品質を確認するため、クラウドソーシングデータと実証実験データそれぞれのアノテーションの一致率を評価する。3人以上のアノテーションの一致率を評価する指標である Fleiss の κ 値を計算したところ、実証実験データの値は0.571、クラウドソーシングデータの値は0.407であり、どちらも中程度の一致率が確認された。クラウドソーシングによるア

応答タイプ	クラウドソーシング	実証実験
1. 明示的な応答	449 (62.4%)	710 (54.5%)
2. 暗黙的な応答	167 (23.2%)	154 (11.8%)
3. 曖昧な応答	71 (9.9%)	133 (10.2%)
4. 無関係な応答	33 (4.6%)	95 (7.3%)
5. 不完全な応答	0 (0.0%)	210 (16.1%)
Total	720	868

表 14: 質問に対する応答タイプの割合

ノテーションでは、明示的な応答と暗黙的な応答で評価が分かれることが特に多く、 κ 値が低くなった。この問題は、クラウドワークに与える指示を整備することで、改善される見込みがある。

表 14 にアノテータ全員のアノテーションの分布を示す。クラウドソーシングと比較すると、実証実験では有効な回答（明示的、暗黙的）の割合が減少し、逆に無効な回答（曖昧、無関係、不完全）の割合が増加していることがわかる。具体的には、クラウドソーシングにおける無効応答の割合が 14.5%(=9.9%+4.6%) であったのに対し、実証実験では 33.6%(=10.2%+7.3%+16.1%) と 2 倍以上に達している。特に注目すべきは、不完全な応答が 16.1% を占めている点である。クラウドソーシングではテキスト入力のため 0% であったのに対し、音声を紹介する実証実験では顕著に増加した。この差は、音声認識やターンテイキングの失敗など、実環境に特有の問題だと考えられる。この結果は、実環境での音声対話において、信頼性のある有効な回答を得ることの難しさを示唆している。

6 おわりに

本研究では、日常的な雑談を通じてアンケートの回答を自然に収集するアンケート対話システムを提案し、その有効性を検証した。本システムは、CoT プロンプトを用いた質問誘導と、LLM を用いた応答と選択肢の対応づけによって構成されており、対話の自然性を保ちながら所望の質問を尋ね、従来の紙面アンケートと同じ形式での回答を収集することが可能である。

クラウドソーシングを用いたテキスト対話による評価実験では、まず一般的な質問を対象とした質問誘導対話を実施し、質問誘導能力を対話者自身による評価および第三者評価により検証した。その結果、CoT プロンプトを用いた質問誘導は、対話の自然性を損なうことなく、所望の質問を自然に尋ねる上で有効であることが示された。続いて、フレイルアンケートを対象とした質問誘導対話を実施し、対話システムを用いて得られた回答と紙面アンケートによる回答との一致率を評価した結果、アンケート対話システムによって得られた回答は、従来の紙面

アンケートと比較的高い一致率を持つことが示された。さらに、高齢者を対象とした実環境での実証実験では、フレイルアンケートを対象とした質問誘導対話を高齢者の自宅で2週間実施し、対話システムを用いて得られた回答と紙面アンケートによる回答との一致率を評価した。その結果、アンケート対話システムによって得られた回答は、紙面アンケートと比較的高い一致率を示し、本システムの実環境における有効性が確認された。

以上より、アンケート対話システムは、高齢者の負担を軽減しながら健康状態を定期的に把握し、フレイルの早期発見に資する可能性を有することが示唆された。

一方で、本研究にはいくつかの課題が残されている。第一に、アンケート対話システムは目標質問をあらかじめ指定したターンで必ず尋ねる設計であったため、既に回答が得られている場合にも同じ質問を尋ねてしまう問題がある。このような、対話の中で既に明らかになっている情報を再度尋ねることは対話破綻であり、対話品質を損なう危険性がある (Higashinaka et al. 2021)。そのため、対話履歴を逐次確認し、質問の回答が明らかになっている場合には質問をスキップするなどの動的制御が必要である。第二に、質問に対して不完全な応答や曖昧な応答が多い点も問題である。特に実証実験では、音声認識やターンテイキングの失敗により不完全な応答が多く発生したため、音声認識システムおよびターンテイキング手法の改善が必要である。加えて、質問に対して明確な回答が得られなかった際に、深掘り質問や確認の発話を行うなど、質問に対する回答を確実に取得するための対話戦略も必要である。第三に、本研究で提案した応答と選択肢の対応づけは単一選択質問のみを対象としており、複数選択や自由記述などの形式で回答する質問を扱うことができない点も改善が必要である。フレイルアンケートを含む医療用のアンケートでは、単一選択以外の形式の質問も広く使用されており、高齢者の健康状態をより包括的に把握するためには、様々な質問形式にも対応可能な対応づけ手法が必要である。

また、高齢者は若者に比べて長く頻繁に話す傾向があり、それが音声認識や言語理解の問題を引き起こすことが指摘されている (Wolters et al. 2009; Vipperla et al. 2009; Georgila et al. 2010)。本研究の実証実験においても、そのような現象が生じていなかったかを今後詳細に分析する必要がある。さらに、実験参加者の多様性を拡大し、より長期的な期間での実験を行うことで、本システムの一般化可能性を検証することも重要である。あわせて、収集した高齢者の健康情報を健康状態の改善に活用するための支援方法についても検討を進めたい。

謝 辞

本研究の一部は、JSPS 科研費 24K14769, 23H00493, 24K05433 の助成を受けたものです。また、実証実験において多大なご協力を賜りました名古屋市北区と豊山町の皆様に厚く感謝いたします。本論文の一部は、言語処理学会第31回年次大会(銭本 他 2025) および The 29th Workshop on the Semantics and Pragmatics of Dialogue (SemDial2025)(Zenimoto et al. 2025) で発表済み

のものです。

参考文献

- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., and Amodei, D. (2020). “Language Models are Few-Shot Learners.” In *Proc. NeurIPS*, pp. 1877–1901.
- Chiba, Y. and Higashinaka, R. (2025). “Investigating the Impact of Incremental Processing and Voice Activity Projection on Spoken Dialogue Systems.” In *Proc. COLING*, pp. 3687–3696.
- Dent, E., Morley, J. E., Cruz-Jentoft, A. J., Woodhouse, L., Rodríguez-Mañas, L., Fried, L. P., Woo, J., Aprahamian, I., Sanford, A., Lundy, J., Landi, F., Beilby, J., Martin, F. C., Bauer, J. M., Ferrucci, L., Merchant, R. A., Dong, B., Arai, H., Hoogendijk, E. O., Won, C. W., Abbatecola, A., Cederholm, T., Strandberg, T., Gutiérrez Robledo, L. M., Flicker, L., Bhasin, S., Aubertin-Leheudre, M., Bischoff-Ferrari, H. A., Guralnik, J. M., Muscedere, J., Pahor, M., Ruiz, J., Negm, A. M., Reginster, J. Y., Waters, D. L., and Vellas, B. (2019). “Physical Frailty: ICFSR International Clinical Practice Guidelines for Identification and Management.” *Journal of Nutrition, Health & Aging*, **23** (9), pp. 771–787.
- Dwass, M. (1960). “Some k-sample rank-order tests.” In *Contributions to Probability and Statistics*, p. 198–202. Stanford University Press.
- Fried, L. P., Tangen, C. M., Walston, J., Newman, A. B., Hirsch, C., Gottdiener, J., Seeman, T., Tracy, R., Kop, W. J., Burke, G., and McBurnie, M. A. (2001). “Frailty in older adults: evidence for a phenotype.” *Journal of Gerontology: Series A, Biological Sciences and Medical Sciences*, **56** (3), pp. M146–M156.
- Geiecke, F. and Jaravel, X. (2024). “Conversations at scale: Robust AI-led interviews with a simple open-source platform.” *Social Science Research Network*, pp. 1–73.
- Georgila, K., Wolters, M., Moore, J. D., and Logie, R. H. (2010). “The MATCH corpus: a corpus of older and younger users’ interactions with spoken dialogue systems.” *Language Resources and Evaluation*, **44** (3), pp. 221–261.
- Gupta, P., Jhamtani, H., and Bigham, J. (2022). “Target-Guided Dialogue Response Generation Using Commonsense and Data Augmentation.” In *Findings of the Association for Computational Linguistics: NAACL 2022*, pp. 1301–1317.

- Hashimoto, E., Nakano, M., Sakurai, T., Shiramatsu, S., Komazaki, T., and Tsuchiya, S. (2025). “A Career Interview Dialogue System using Large Language Model-based Dynamic Slot Generation.” In *Proc. COLING*, pp. 1562–1584.
- Hayashi, T., Noguchi, T., Watanabe, R., Kubo, Y., Tsuji, T., Saito, M., and Kondo, K. (2026). “Multi-dimensional social frailty index for predicting disability and mortality in community-dwelling older adults: JAGES cohort.” *Archives of Gerontology and Geriatrics*, **143**, p. 106158.
- Higashinaka, R., Araki, M., Tsukahara, H., and Mizukami, M. (2021). “Integrated taxonomy of errors in chat-oriented dialogue systems.” In *Proc. SIGDIAL*, pp. 89–98.
- Horiuchi, S. and Higashinaka, R. (2021). “Learning to ask specific questions naturally in chat-oriented dialogue systems.” In *Proc. IWSDS*, pp. 1–13.
- Horiuchi, S. and Higashinaka, R. (2023). “Learning to guide questions in chat-oriented dialogue by using combination of question-guiding corpora.” In *Proc. IWSDS*, pp. 1–15.
- Ji, H., Ke, P., Huang, S., Wei, F., Zhu, X., and Huang, M. (2020). “Language Generation with Multi-Hop Reasoning on Commonsense Knowledge Graph.” In *Proc. EMNLP*, pp. 725–736.
- Johnston, M., Ehlen, P., Conrad, F. G., Schober, M. F., Antoun, C., Fail, S., Hupp, A., Vickers, L., Yan, H., and Zhang, C. (2013). “Spoken Dialog Systems for Automated Survey Interviewing.” In *Proc. SIGDIAL*, pp. 329–333.
- Kishinami, Y., Akama, R., Sato, S., Tokuhisa, R., Suzuki, J., and Inui, K. (2022). “Target-Guided Open-Domain Conversation Planning.” In *Proc. COLING*, pp. 660–668.
- Kobori, T., Nakano, M., and Nakamura, T. (2016). “Small Talk Improves User Impressions of Interview Dialogue Systems.” In *Proc. SIGDIAL*, pp. 370–380.
- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., and Iwasawa, Y. (2022). “Large Language Models are Zero-Shot Reasoners.” In *Proc. NeurIPS*, pp. 22199–22213.
- Mann, H. B. and Whitney, D. R. (1947). “On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other.” *Annals of Mathematical Statistics*, **18** (1), pp. 50–60.
- 舩田ゆづり, 悦子, 臺有桂 (2012). 高齢者における日本語版 UCLA 孤独感尺度 (第3版) の開発とその信頼性・妥当性の検討. 日本地域看護学会誌, **15** (1), pp. 25–32. [Y.Masuda et al. (2012). Koreisha ni okeru Nihongoban UCLA Kodokukan Shakudo (Dai 3 Han) no Kaihatsu to sono Shinraisei, Datosei no kento. Journal of Japan Academy of Community Health Nursing, 15(1), pp.25-32.].
- 村瀬訓生, 勝村俊仁, 上田千穂子, 井上茂, 下光輝一 (2002). 身体活動量の国際標準化—IPAQ 日本語版の信頼性, 妥当性の評価. 厚生の指標, **49** (11), pp. 1–9. [N. Murase et al. (2002). Shintai Katsudoryo no Kokusai Hyojunka: IPAQ Nihongo-ban no Shinraisei, Datosei no

- Hyoka. Kosei no Shihyo, 49(11), 1–9.].
- Nagasawa, F., Okada, S., Ishihara, T., and Nitta, K. (2024). Adaptive Interview Strategy Based on Interviewees’ Speaking Willingness Recognition for Interview Robots. *IEEE Transactions on Affective Computing*, **15** (3), pp. 942–957.
- Qin, J., Ye, Z., Tang, J., and Liang, X. (2020). “Dynamic Knowledge Routing Network for Target-Guided Open-Domain Conversation.” In *Proc. AAAI*, Vol. 34, pp. 8657–8664.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., and Sutskever, I. (2019). “Language Models are Unsupervised Multitask Learners.” *OpenAI Blog*, **1** (8), pp. 1–9.
- 佐竹昭介 (2018). 基本チェックリストとフレイル. 日本老年医学会雑誌, **55** (3), pp. 319–328. [S. Satake (2018). Kihon Chekkurisuto to Fureiru. Nihon Ronen Igakkai Zasshi, 55(3), 319–328.].
- Sevegnani, K., Howcroft, D. M., Konstas, I., and Rieser, V. (2021). “OTTERS: One-turn Topic Transitions for Open-Domain Dialogue.” In *Proc. ACL*, pp. 2492–2504.
- Small, M. L. and Calarco, J. M. (2022). *Qualitative Literacy: A Guide to Evaluating Ethnographic and Interview Research*. University of California Press.
- Speer, R., Chin, J., and Havasi, C. (2017). “ConceptNet 5.5: an open multilingual graph of general knowledge.” In *Proc. AAAI*, p. 4444–4451.
- Sugiyama, H., Mizukami, M., Arimoto, T., Narimatsu, H., Chiba, Y., Nakajima, H., and Meguro, T. (2023). “Empirical Analysis of Training Strategies of Transformer-Based Japanese Chit-Chat Systems.” In *Proc. SLT*, pp. 685–691.
- Tang, J., Zhao, T., Xiong, C., Liang, X., Xing, E., and Hu, Z. (2019). “Target-Guided Open-Domain Conversation.” In *Proc. ACL*, pp. 5624–5634.
- Vipperla, R., Wolters, M., Georgila, K., and Renals, S. (2009). “Speech Input from Older Users in Smart Environments: Challenges and Perspectives.” In *Proc. Universal Access in Human-Computer Interaction. Intelligent and Ubiquitous Interaction Environments*, pp. 117–126.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V., and Zhou, D. (2022). “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.” In *Proc. NeurIPS*, pp. 24824–24837.
- Wilson, M. M. G., Thomas, D. R., Rubenstein, L. Z., Chibnall, J. T., Anderson, S., Baxi, A., Diebold, M. R., and Morley, J. E. (2005). “Appetite assessment: Simple appetite questionnaire predicts weight loss in community-dwelling adults and nursing home residents.” *The American Journal of Clinical Nutrition*, **82** (5), pp. 1074–1081.
- Wolters, M., Georgila, K., Moore, J. D., and MacPherson, S. E. (2009). Being Old Doesn’t Mean Acting Old: How Older Users Interact with Spoken Dialog Systems. *ACM Transactions on Accessible Computing*, **2** (1), pp. 1–39.

- Xiao, Z., Zhou, M. X., Liao, Q. V., Mark, G., Chi, C., Chen, W., and Yang, H. (2020). “Tell Me About Yourself: Using an AI-Powered Chatbot to Conduct Conversational Surveys with Open-ended Questions.” *ACM Transactions on Computer-Human Interaction*, **27** (3), pp. 1–37.
- Xu, J., Wang, H., Niu, Z.-Y., Wu, H., Che, W., and Liu, T. (2020). “Conversational Graph Grounded Policy Learning for Open-Domain Conversation Generation.” In *Proc. ACL*, pp. 1835–1845.
- Yang, Z., Wang, B., Zhou, J., Tan, Y., Zhao, D., Huang, K., He, R., and Hou, Y. (2022). “TopKG: Target-oriented Dialog via Global Planning on Knowledge Graph.” In *Proc. COLING*, pp. 745–755. *International Committee on Computational Linguistics*.
- Yoshida, M., Hori, R., Zenimoto, Y., Urata, M., Endo, M., Yasuda, T., Inoue, A., Hayashi, T., and Higashinaka, R. (2025). “Examining Older Adults’ Motivation for Interacting with Health-Monitoring Conversational Systems Through Field Trials.” In *Proc. IWSDS*, pp. 103–114.
- 吉田麻里子, 堀涼, 銭本友樹, 浦田真由, 遠藤守, 安田孝美, 井上愛子, 林尊弘, 東中竜一郎 (2025). 高齢者健康支援のための生成 AI を活用した雑談システムの開発～実証実験を通じた利用モチベーションの検証～. 第 15 回社会情報学会中部支部研究会, pp. 1–4. [M. Yoshida et al. (2025). Koreisya Kenko Shien no Tame no Seisei AI wo Katsuyo Shita Zatsudan Shisutemu no Kaihatsu Jissho Jikken wo Toshita Riyo Mochibeshon no Kensho, Dai 15 Kai SyakaiJohogakugakkai Chubushibu Kenkyukai, pp. 1-4.].
- Zenimoto, Y., Yoshida, M., Hori, R., Urata, M., Inoue, A., Hayashi, T., and Higashinaka, R. (2025). “Automated Administration of Questionnaires during Casual Conversation using Question-Guiding Dialogue System.” In *Proc. SemDial*, pp. 1–10.
- 銭本友樹, 吉田麻里子, 堀涼, 浦田真由, 井上愛子, 林尊弘, 東中竜一郎 (2025). 質問誘導に基づくアンケート対話システムの開発. 言語処理学会 第 31 回年次大会 発表論文集, pp. 4005–4010. [Y. Zenimoto et al. (2025). Shitsumon Yudo ni Motodoku Anketo Taiwa Shisutem no Kaihatsu. Gengoshorigakkai Dai 31 Kai Happyo Ronbunshuu, pp. 4005-4010.].
- Zhong, P., Liu, Y., Wang, H., and Miao, C. (2021). “Keyword-Guided Neural Conversational Model.” In *Proc. AAAI*, Vol. 35, pp. 14568–14576.

付録

A 質問誘導プロンプト

図 10 および図 11 に、質問誘導プロンプト A, B の具体例を示す。

文脈を考慮して、目標質問を尋ねても違和感のないような話の流れに対話を自然に誘導してください。
 まだセリフには目標質問を含めないでください。目標質問と全く同じ意味のセリフの出力は禁止です。次の次のセリフで目標質問を尋ねることを考えて、対話を誘導してください。
 対話を誘導するためのthoughtとして、「目標質問を尋ねる話の流れになっているか」、「現在は何についての話か」「目標質問は何についての質問か」「どうすれば目標質問を尋ねても違和感のない話の流れに誘導できるか」を考えた後に、セリフを出力してください。
 以下のような接続詞を使って無理やり話の流れを大きく変えることは絶対に禁止です。文脈に合った誘導をしてください。
 # 禁止接続詞
 「ところで」、「そういえば」、「ちなみに」、「それはさておき」、「それにしても」、「さて」、「話は変わ」、「例えば」（後略）

<ショット例>
 # 目標質問
 あなたは学校の宿題を代行業者に依頼したことはありますか？
 # 文脈
 システム：こんにちは。
 ユーザー：こんにちは。あなたは生活費とかお金の管理って得意ですか？
 システム：うーん。苦手です。家計簿とかこまめにつけることもしていないので、成り行き任せですね。
 ユーザー：わかります。私もお金の管理って苦手です。最近はキャッシュレス決済も多いので、気づいたら使いすぎてるってのが多いです。
 # thought
 Let's think step by step.
 目標質問を尋ねる話の流れになっているか：いいえ
 現在は何についての話か：お金の管理やキャッシュレス決済
 目標質問は何についての質問か：宿題を代行業者に依頼したことがあるか
 どうすれば目標質問を尋ねても違和感のない話の流れに誘導できるか：お金の管理についての話から、こまごまとした作業についての話に言及した後、こまごまとした作業である宿題について言及することで、自然に目標質問を尋ねる話の流れになりそうである。そこで、文脈に沿った応答をした後、宿題のやりかたについて言及する。この時、まだ目標質問は尋ねない。
 # 出力
 システム：そうですね。一応履歴をみれるのが救いですが。昔からコツコツするのが苦手で、夏休みの宿題とかもまとめてやっちゃうタイプでした。あなたはどうですか？
 <ショット例>

```
# 目標質問
{target_question}
# 文脈
{context}
# thought
Let's think step by step.
```

図 10: 質問誘導プロンプト A の具体例。{target_question} には実際に尋ねる目標質問が入り、{context} には対話履歴が入る。

B 作業画面

図 12 に対話システムとの対話画面、図 13 に対話の評価画面、図 14 に対応づけの作業画面を示す。

文脈を考慮して、目標質問を尋ねても違和感のないような話の流れに対話を自然に誘導してください。
 まだセリフには目標質問を含めないでください。目標質問と全く同じ意味のセリフの出力は禁止です。次のセリフで目標質問を尋ねることを考えて、対話を誘導してください。
 対話を誘導するためのthoughtとして、「目標質問を尋ねる話の流れになっているか」、「現在は何についての話か」「目標質問は何についての質問か」「どうすれば目標質問を尋ねても違和感のない話の流れに誘導できるか」を考えた後に、セリフを出力してください。
 長い出力は禁止です、出力は簡潔に短くしてください。
 以下のような接続詞を使って無理やり話の流れを大きく変えることは絶対に禁止です。文脈に合った誘導をしてください。
 # 禁止接続詞
 「ところで」、「そういえば」、「ちなみに」、「それはさておき」、「それにしても」、「さて、」、「話は変わ」、「例えば」（後略）

<ショット例>
 # 目標質問
 あなたの卒業高校は地域での評判は良いですか？
 # 文脈
 ユーザー：こんにちは。
 システム：こんにちは。最近どこか遊びに行かれましたか？
 ユーザー：家族で大阪に旅行に行きました。あなたはどこか行きましたか？
 システム：いいですね、宿泊しましたか？私はコロナで全然いけないです。せっかくなので旅行支援使いたかったのですが。
 ユーザー：はい、旅行支援使って、宿泊と観光をしましたよ。ユニバに行ったんですが、とても楽しかったです。
 システム：いいですね！ユニバもどんどん新しいのが追加されてますよね。ハリーポッター乗りましたか？
 ユーザー：乗りましたー！世界観最高でした。マリオのエリアもすごかったですよ。
 # thought
 Let's think step by step.
 目標質問を尋ねる話の流れになっているか：いいえ
 現在は何についての話か：旅行やUSJ
 目標質問は何についての質問か：卒業高校の地域での評判
 どうすれば目標質問を尋ねても違和感のない話の流れに誘導できるか：USJの話から学生時代のUSJの思い出に誘導することで、自然に目標質問を尋ねる話の流れになりそうである。そこで、文脈に沿った応答をした後、学生自体のUSJの思い出について言及し、目標質問を尋ねる話の流れを作る。この時、まだ目標質問は尋ねない。
 # 出力
 システム：マリオはいったことないので行きたいですね。高校の卒業旅行でUSJに行ったのが懐かしいです。あなたは卒業旅行どこに行きましたか？
 <ショット例>

目標質問
 {target_question}
 # 文脈
 {context}
 # thought
 Let's think step by step.

図 11: 質問誘導プロンプト B の具体例。{target_question} には実際に尋ねる目標質問が入り、{context} には対話履歴が入る。



図 12: クラウドワークに提示した対話システムとの対話画面

特定の質問を行う対話システムを評価する仕事
ユーザー名: test ユーザーID: 9999

以下の目標質問と対話を読んで、システムの応答を評価してください。対話は必ず最初から最後まで読んで評価してください。今回の作業では、複数の対話を評価していただきますが、各対話はそれぞれ独立に評価してください。

目標質問: 自分の性格で嫌いなところはありますか?


システム

こんにちは。よろしくお願いします。


ユーザー


システム

よろしくお願いします。あなたは車を運転することができますか?


ユーザー


システム

わたしは免許はありますがペーパードライバーやっています。


ユーザー


システム

(A) そうですね、都会に住んでいるので公共交通機関が発達していて、車を使う必要がありません。


ユーザー


システム

確かに、都会では便利です。どの交通機関をよく利用しますか?


ユーザー


システム

(B) 地下鉄をよく利用します。通勤や買い物にも便利で、自分の時間を有効に使えるのがいいですね。


ユーザー


システム

地下鉄は便利です。混んでいる時間帯は大変ではありませんか?


ユーザー


システム

(C) 確かに、ラッシュアワーは大変ですね。でも、混雑を避けるために時間を調整したり、読書をしたりしています。自分の性格で嫌いなところはありますか?


ユーザー


システム

私はせっかちになりがちです。もう少しゆっくり考えるようにしたいです。


ユーザー

進捗: 2 / 15

評価

項目1: 最後の対話の流れ（ウェブ画面上で赤線で囲まれている部分）は対話として自然である。

☐ 1.全く当てはまらない

☐ 2.当てはまらない

☐ 3.どちらともいえない

☐ 4.当てはまる

☐ 5.非常によく当てはまる

項目2: システム発話Aに目標質問が含まれている。
(完全に同じ文章が含まれていなくても、同じ意味の質問が行われていれば「1.はい」を選択してください。同じ意味の質問とは、言い換えると同じ文章になる質問と考えてください。)

☐ 1.はい

☐ 2.いいえ

項目3: システム発話Bに目標質問が含まれている。

☐ 1.はい

☐ 2.いいえ

項目4: システム発話Cに目標質問が含まれている。

☐ 1.はい

☐ 2.いいえ

項目5: システム発話Aのおかげで目標質問が尋ねやすくなっている。

☐ 1.全く当てはまらない

☐ 2.当てはまらない

☐ 3.どちらともいえない

☐ 4.当てはまる

☐ 5.非常によく当てはまる

項目6: システム発話Bのおかげで目標質問が尋ねやすくなっている。

☐ 1.全く当てはまらない

☐ 2.当てはまらない

☐ 3.どちらともいえない

☐ 4.当てはまる

☐ 5.非常によく当てはまる

図 13: クラウドワークに提示した対話の評価画面。なお、「システム発話 A」は 1 回目の誘導発話、「システム発話 B」は 2 回目の誘導発話、「システム発話 C」は質問を尋ねる発話のことである。

質問に対する応答を評価する仕事

ユーザー名: test ユーザーID: 9999

画面左の評価ガイドラインを参考に、画面右の評価項目に回答してください。

評価ガイドライン

項目Aの選択肢ごとの具体例

以下で出てくる「明確な回答」とは、質問で求められている回答のタイプで直接答えている回答のことである。例えば、yes, noで答える質問に対して、「はい」と答え、回数で答える質問に対して、「3回」と答えているような回答が「明確な回答」である。

- 1. 応答は、質問に対する明確な回答をしている
質問：「半年前に比べて固いものが食べにくくなりましたか？」
応答：「はい、難しくなりました」
- 2. 応答は、質問に対する明確な回答はしていないが、回答を推論することができる
質問：「普段の食事は何回とりますか？」
応答：「朝は食べずに昼と夜だけ食べます」（1日2回であることが推論できる）
- 3. 応答は、質問と関係しているが、回答を推論することができない
質問：「食べ物の味が美味しいと感じますか？」
応答：「デザートはやっぱり食べたいですね」
- 4. 応答は、質問とは全く関係がない
質問：「お茶や汁物等でむせることがありますか？」
応答：「今日の天気を教えてください」
- 5. 応答は、文章が途中で途切れている、あるいは非文であり、回答を推論することができない
質問：「自分は他の人たちから孤立していると感じることはありますか？」
応答：「どちらかというと」

項目Bの回答例

- 例1
質問：「半年前に比べて固いものが食べにくくなりましたか？」
応答：「はい、難しくなりました」
選択肢：
・ はい←こちらを選択
・ いいえ
- 例2
質問：「現在の暮らしの状況について、経済的にみてどう感じていますか？」
応答：「あまり余裕はないです」
選択肢：
・ ゆとりがある
・ ややゆとりがある
・ ふつう
・ やや苦しい←こちらを選択
・ 苦しい

評価項目

進捗: 1 / 40

項目A：以下の質問と応答について、最も当てはまる選択肢を選んでください。

質問：「階段を手すりや壁をつたわずに昇っていますか？」

応答：「何も使わず昇っていますよ。」

選択肢：

- ☐ 1. 応答は、質問に対する明確な回答をしている
- ☐ 2. 応答は、質問に対する明確な回答はしていないが、回答を推論することができる
- ☐ 3. 応答は、質問と関係しているが、回答を推論することができない
- ☐ 4. 応答は、質問とは全く関係がない
- ☐ 5. 応答は、文章が途中で途切れている、あるいは非文であり、回答を推論することができない

項目B：（前の項目で、1・2のいずれかを選んだ場合）以下の質問と応答について、応答で答えている内容と最も意味が近い選択肢を選んでください。

（前の項目で、3・4・5のいずれかを選んだ場合は、「対象外」を選んでください。）

質問：「階段を手すりや壁をつたわずに昇っていますか？」

応答：「何も使わず昇っていますよ。」

選択肢：

- ☐ はい
- ☐ いいえ
- ☐ 対象外

次へ

図 14: クラウドワークに提示した対応づけの作業画面

略歴

銭本友樹：筑波大学大学院理工情報生命学術院システム情報工学研究群博士前期課程修了。現在，名古屋大学大学院情報学研究科博士後期課程在学中。対話システム，発話者分類，口調の研究に従事。人工知能学会，言語処理学会，情報処理学会各会員

吉田麻里子：2024 年名古屋大学情報学部人間・社会情報学科卒業。現在，名古屋大学大学院情報学研究科社会情報学専攻博士前期課程修了。高齢者の ICT 利活用の研究に従事。

堀涼：2025 年名古屋大学大学院情報学研究科博士後期課程修了。現在，学振特別研究員（PD）。非専門家によるデジタルやデータ利活用による観光まちづくりの研究に従事。情報処理学会，IEEE，観光情報学会，地域活性学会各会員。博士（情報学）。

浦田真由：2011 年名古屋大学大学院情報科学研究科博士後期課程修了。同年，同大学大学院国際開発研究科助教，2017 年同大学大学院情報学研究科講師，2021 年同大学同研究科教授，現在に至る。2017 年より総務省地域情報化アドバイザー，2019 年より内閣官房（現在：デジタル庁）オープンデータ伝道師を務め，自治体や企業，地域コミュニティと連携し，社会情報学の視点に基づいて，地域の活性化や情報化を促す実践的な研究に従事。観光情報学会，情報文化学会，社会情報学会，各会員。博士（情報科学）。

井上愛子：2017 年名古屋大学大学院医学系研究科博士課程修了。博士（医学）。現在，名古屋大学未来社会創造機構 特任講師。名古屋大学大学院医学系研究科地域在宅医療学・老年科学講座に所属し，高齢者の在宅医療およびフレイル予防に関する研究・実践に従事。特に，デジタル技術や AI を活用した行動変容支援，地域包括ケアモデルの構築，健康寿命延伸を目的とした介入の社会実装に注力している。日本老年医学会，日本サルコペニア・フレイル学会（評議員），各会員。

林尊弘：2015 年日本福祉大学大学院 社会福祉学研究科 博士後期課程 修了。博士（社会福祉学）。現在，愛知医療学院大学 リハビリテーション学部 准教授。高齢者のフレイルおよびサルコペニア予防に関する研究に従事。特に，ICT を用いた社会的フレイルの介入方略の構築や超音波診断装置を用いたリハビリテーション患者の筋質評価に関する研究に従事。日本老年医学会，日本サルコペニア・フレイル学会，日本公衆衛生学会，日本疫学会，各会員。

東中竜一郎：2001 年慶應義塾大学大学院政策・メディア研究科博士前期課程，2008 年博士後期課程修了。2001 年日本電信電話株式会社入社。2020 年より，

名古屋大学大学院情報学研究科教授. NTT 人間情報研究所客員上席特別研究員. 慶應義塾大学環境情報学部特別招聘教授. 2004 年から 2006 年まで英国シェフィールド大学客員研究員. 質問応答システム・対話システムの研究に従事. 人工知能学会, 言語処理学会, 情報処理学会, 電子情報通信学会各会員. 博士 (学術).